

# פרוייקט גמר - דוח סופי

רכז פרוייקט: ד"ר ינון צוקרמן

מנחה אקדמאי: ד"ר רפאלי אורית

מנחה תעסוקתי: ליאור קוטלר

## קבוצה מספר 8:

מרינה נז'לסקי 321859969

אייל קדוש 208005280

עדן כהן 209056225

## תוכן עניינים

1.	תקציר מנהלים	2
2.	תיאור הארגון	3
3.	1. תהליך ה S&OP	3
4.	2. אופן ביצוע התהליך	4
3.	3. תיאור הנדסי של המצב הקיים	5
5.	1. מבנה ארגוני ותפקידים בצוות	5
5.	2. פעילויות מרכזיות של הצוות	5
6.	3. חשיבות התהליך לאינטל	6
7.	4. תרשים זרימה	7
8.	5. תרשים BPMN	8
4.	4. הגדרת הבעיה	9
9.	1. בעיה ראשונה	9
10.	2. בעיה שנייה	10
5.	5. מטרת הפרוייקט	11
12.	1. מדדי הערכה	12
14.	2. אילוצים פנימיים וחיצוניים	14
15.	6. תרשים גאנט	15
16.	7. סקר ספרות	16
20.	1. תובנות מסקר הספרות	20
21.	8. מתודולוגיה	21
23.	9. הצגת חלופות	23
25.	1. הנמקה לפתרון הנבחר	25
26.	10. מימוש הפתרון	26
26.	1. פתרון בעיה ראשונה	26
27.	2. פתרון בעיה שנייה	27
28.	i. ניסויים לבחירת מודל אופטימלי	28
30.	ii. הפתרון הנבחר	30
31.	3. משוב מהמשתמשים	31
32.	4. כוילים ושיפורים	32
34.	11. הערכת הפתרון	34
36.	12. דיון, מסקנות והמלצות	36
36.	1. תובנות מרכזיות	36
37.	2. מסקנות והמלצות	37
37.	3. תרומת חברי הצוות להצלחת הפרוייקט	37
38.	13. ביבליוגרפיה	38
39.	14. נספחים	39

## 1. תקציר מנהלים

אינטל הוא אחד התאגידים המובילים בעולם בתכנון וייצור מיקרו-מעבדים וטכנולוגיות רשת ותקשורת מתקדמות. מוצריה כוללים מעבדים למחשבים אישיים, מעבדי שרתים וענן, ופתרונות לרכב חכם ואוטונומי. החברה פועלת בשוק תחרותי מאוד ומתמקדת בפיתוח שבבים חדשניים עם דגש על ביצועים גבוהים.

Sales and Operations Planning (S&OP) הוא תהליך ניהולי אינטגרטיבי המסייע לארגונים לתאם בין תחזיות הביקוש, תכנון הייצור וניהול המלאי במטרה לשפר את הביצועים העסקיים ולשמור על איזון בין מכירות לאספקה. אינטל מתמודדת עם תהליך S&OP ידני, איטי ולא מדויק מספיק, אשר פוגע בתגובתה לשינויים בשוק וגורם לעיכובים משמעותיים, טעויות אנוש ולביצועים לא אופטימליים.

הפרויקט שלנו עוסק בשיפור תהליך ה-S&OP באינטל באמצעות אוטומציה מתקדמת וכלי BI. מטרת הפרויקט היא להטמיע מערכת אוטומציה לשיפור איסוף וניתוח הנתונים, פיתוח אלגוריתם חיזוי מתקדם לביקושים והאצת תהליך קבלת ההחלטות. השגת היעדים תביא להפחתת טעויות אנוש, שיפור דיוק התחזיות, יעול התהליכים וצמצום זמני העבודה המונוטוניים.

לצורך איפיון התהליך, ראשית ביצענו מיפוי של התהליכים הנוכחיים והמצב הקיים כיום בעזרת סקר ותשאול המהנדסים המעורבים בתהליך. לאחר מכן, נאספו נתוני הביקוש, האספקה והייצור והוגדרו הדרישות העסקיות והטכניות של המערכת החדשה.

נעשתה השוואה בין חלופות אפשריות לפתרון ובבחר השימוש ב Power BI כמערכת האופטימלית לפיתוח הדאשבורד, ו-Python ככלי לפיתוח אלגוריתם חיזוי הביקושים.

לאחר מכן נעשה עיבוד וניקוי הנתונים מהעבר, פיתוח מודלי חיזוי מתקדמים והקמת מערכת BI. לאחר בדיקת מדדי ההערכה והשוואתם למצב הקודם, קיבלנו משוב על המערכת והמודל חיזוי מהמהנדסים, ולבסוף, הטמענו את המערכת בארגון, ופיתחנו תוכנית הכשרה למשתמשים.

הפרויקט מהווה פתרון אשר ישפר את יעילות ודיוק תהליך ה-S&OP בחברה, תוך התמקדות בשיפור זמני ביצוע, הפחתת טעויות וניהול משאבים מתקדם.

## 2. תיאור הארגון

אינטל הוא תאגיד רב לאומי-אמריקאי, מהחברות המובילות בעולם בתחום של תכנון וייצור מיקרו-מעבדים ומעגלים משולבים. מוצריה כוללים מעבדים למחשבים אישיים (Intel Core), מעבדי שרתים (Intel Xeon), פתרונות לרכב חכם ואוטונומי (Mobileye), וטכנולוגיות רשת ותקשורת מתקדמות. החברה מתמקדת בפיתוח שבבים חדשניים עם דגש על ביצועים, יעילות אנרגטית ואינטגרציה חכמה.

אינטל מפעילה מעל ל-20 מרכזי פיתוח וכ-10 מפעלי ייצור ברחבי העולם בהם מיוצרים מוצריה בכלל הטכנולוגיות השונות. לחברה מגוון רחב של לקוחות בשווקים שונים. בתחום המחשוב האישי היא משתפת פעולה עם חברות כגון HP, Dell ו-Lenovo, המשתמשות במעבדי Intel Core במחשבים האישיים שלהן. בתחום השרתים והענן, חברות מובילות כמו Amazon Web Services (AWS), Microsoft Azure ו-Google Cloud משתמשות במעבדי Intel Xeon. בנוסף, אינטל מציעה פתרונות לרכב חכם ואוטונומי בעזרת טכנולוגיות Mobileye, שאומצו על ידי חברות כמו BMW, Ford ו-Volkswagen.

הביקוש למעבדי אינטל משתנה בהתאם למגמות בשוק. בשוק הגיימינג והמחשוב האישי יש ביקוש גבוה למעבדים עוצמתיים, בעוד שבתחום השרתים והענן נרשם גידול מתמיד בביקוש למעבדי שרתים המתאימים למחשוב מבוסס בינה מלאכותית. כמו כן, ישנה הרחבה בביקוש לטכנולוגיות רכב אוטונומי ולפתרונות חכמים.

שוק השבבים הוא שוק תחרותי מאד, בו אינטל מתמודדת עם תחרות עזה מחברות כמו AMD בתחום המעבדים, NVIDIA בתחום הבינה המלאכותית והגיימינג, ו-TSMC בתחום ייצור השבבים המתקדמים. אסטרטגיית הייצור של אינטל (IDM 2.0) (Integrated Device Manufacturer 2.0), משלבת ייצור פנימי בטכנולוגיות מתקדמות, מיקור חוץ מקבילי משנה להשלמת ייצור, והצעת שירותי ייצור (Foundry) ללקוחות חיצוניים.

---

### 2.1 תהליך ה-S&OP

**S&OP (Sales and Operations Planning)** הוא תהליך ניהולי אינטגרטיבי המסייע לארגונים לתאם בין תחזיות הביקוש, תכנון הייצור וניהול המלאי. המטרה של תהליך S&OP היא לשפר את הביצועים העסקיים על ידי סנכרון ושיתוף פעולה בין מחלקות המכירות, הייצור, הלוגיסטיקה והאספקה. התהליך מאפשר לארגונים להגיב במהירות לשינויים בביקוש, לנהל משאבי ייצור באופן יעיל, ולייעל את שרשרת האספקה תוך כדי שיפור המתמיד של הביצועים.

## 2.2. אופן ביצוע התהליך

### 1. איסוף נתונים

- נתוני ביקוש: התהליך מתחיל באיסוף תחזיות של המכירות, ניתוח מגמות שוק ונתוני עבר כדי להבין את הביקוש הצפוי. הנתונים האלו כוללים תחזיות מכירות מקבוצות המכירה והשיווק, דפוסי עונתיות, נתוני לקוחות ומידע לגבי מוצרים חדשים.
- נתוני ייצור: בנוסף לנתוני הביקוש, נאספים נתונים על קיבולת הייצור, מגבלות הייצור, מצב המלאי הנוכחי, ומידע על זמינות משאבים וחומרי גלם. נתונים אלו כוללים דיווחי ייצור שוטפים, ניתוחי קיבולת, ותובנות לגבי קווי ייצור ומלאים קיימים.

### 2. ניתוח הנתונים

- ניתוח הביקוש הצפוי: השלב הבא הוא ניתוח הנתונים שנאספו לצורך תחזיות ביקוש לעתיד והתאמת תכניות הייצור בהתאם. התהליך כולל ניתוח סטטיסטי ודיונים בין מחלקות כדי לקבוע את הביקוש המצופה.
- בחינת מגבלות אספקה ומשאבים זמינים: בחינת המגבלות האספקה ומשאבים זמינים, לרבות חומרי גלם, זמן ייצור, כח אדם, וכושר הייצור הנוכחי. כאן מבוצע חישוב על מגבלות אפשריות והתאמות נדרשות על מנת לענות על הביקוש באופן מיטבי.

### 3. יישור תוכניות

- יצירת תוכנית אסטרטגית: יצירת תוכנית אסטרטגית שמתחשבת בכל הנתונים שהצטברו. התוכנית משלבת תכנון מכירות, ייצור ולוגיסטיקה על מנת להבטיח עמידה ביעדים. תוכנית זו כוללת חלוקת משאבים, לו"ז אספקות, תחזיות מלאי ותקציב פיננסי.

### 4. ביצוע ובקרה

- יישום התוכנית: לאחר יצירת התוכנית האסטרטגית, מגיע שלב היישום. הפעולות המבוססות על התוכנית מבוצעות בפועל בכל המחלקות הרלוונטיות: מכירה, ייצור, לוגיסטיקה ומלאי.
- מעקב שוטף ושיפור מתמיד: התהליך מחייב מעקב שוטף אחר ביצועי התוכנית והתקדמותה בהתאם לתחזיות. ניתוח ביצועי ו-Key Performance Indicators (KPI) מאפשר זיהוי חריגות ושינויים בשוק המצריכים התאמות ושיפורים בתוכנית. השיפורים האלו מבוצעים כדי לייעל את התחזיות והתוכניות עתידיות.



### 3. תיאור הנדסי של המצב הקיים

#### 3.1. מבנה ארגוני ותפקידים בצוות S&OP

הצוות מורכב מארבעה מהנדסים מומחים. מטרת הצוות היא לכתוב תכניות אסטרטגיות לטווח הקצר (שנתיים קדימה) לניהול התהליכים הקריטיים של הביקוש והייצור בכל מפעלי אינטל בעולם. מידי חודש המהנדסים מבצעים את התהליך עבור נתוני תחזיות הביקוש, האספקה והייצור, כאשר כל אחד מחברי הצוות מתמקד בהיבט שונה בתהליך:

- מנהל הקבוצה: אחראי על ניהול כולל של צוות S&OP, פיתוח התוכנית האסטרטגית בשיתוף פעולה עם כל חברי הצוות. הוא מוביל את התכנון האסטרטגי, מבצע את התיאומים הנדרשים בין המחלקות ומנהל את הצגת התכנית למנהלים בכירים.
- שלושה מהנדסי תחזיות ביקוש: אחראיים על איסוף וניתוח הנתונים, כמו כן הכנת המצגת. הם משלבים נתוני ייצור שוטפים, נתוני מלאי ותובנות לגבי קווי ייצור כדי לקבוע את היכולת להתאים את הייצור לביקוש. כל אחד מהם מתמקד בניתוח הנתונים עבור טכנולוגיות ומפעלים ספציפיים של אינטל, מזהה פערים וניצולת ייצור ומציע פתרונות לשיפור וביצוע התאמות.

לבסוף מתקיימות מספר ישיבות חודשיות בהן הצוות מציג את התחזיות והתוכניות לכל אחת מהטכנולוגיות של אינטל בפני שרשרת של מנהלים בכירים. בישיבות אלו דנים על תרחישים שונים, ניתוחי רגישות והמלצות להחלטות ניהוליות.

#### 3.2. פעילויות מרכזיות של הצוות

##### 1. ניתוח נתוני הביקוש, הייצור והאספקה

- קבלת הנתונים: מידי חודש הקבוצה מקבלת את תחזית הביקוש ממחלקת ה-Demand כקובץ אקסל ידני במייל, ואת נתוני הייצור והאספקה ממחלקת ה-Production אותם היא מייצאת כקובץ אקסל ידני ממערכת ה-MRP.
- ניתוח הנתונים: עבור כל טכנולוגיה של אינטל בכל מפעל בעולם, הצוות מבצע ניתוחים סטטיסטיים בצורה ידנית באקסל, ומצליב בין הביקושים ויכולות האספקה מול קיבולת הייצור של כל מפעל, במטרה לוודא שהתוכנית מתאימה ליכולת הייצור המעשית.
- זיהוי פערים: הצוות מנתח את הפערים בין דרישות הביקוש הגלובליות, יכולות הייצור הנוכחיות ונתוני האספקה. על בסיס זיהוי הפערים, הצוות מספק פתרונות משולבים הכוללים שינויים בקיבולות הייצור וקביעת קדימויות בהתקדמות הייצור השוטף.
- השוואות מול נתוני ביקוש קודמים: ניתוח נתוני ביקוש עכשוויים לעומת תחזיות ונתונים קודמים כדי לזהות מגמות וסטיות, ולבצע התאמות נדרשות בתוכניות.

## 2. בניית תוכניות אסטרטגיות

- פיתוח תוכניות מותאמות: הקבוצה יוצרת תוכניות אסטרטגיות המסנכרות בין צרכי הלקוחות והיכולות התפעוליות של אינטל, תוך התחשבות בכל המגבלות והמשאבים הקיימים.
- גיבוש והצגה: מידי חודש, הקבוצה מכינה מצגת מקיפה עבור כל טכנולוגיה של אינטל המציגה את הממצאים וההמלצות שלה בפני מנהלי אינטל הבכירים. המצגת כוללת תרחישים אפשריים, ניתוחי רגישות, והמלצות להחלטות ניהוליות.
- פורום ניהולי: בישיבות אלו מתקבלות החלטות חשובות על ידי הדרגים הניהוליים הבכירים של אינטל, בהתבסס על הנתונים וההמלצות שהוצגו.

## 3. מעקב ושיפור מתמשך

- מעקב שוטף: הקבוצה עוקבת אחר יישום והוצאה לפועל של התוכניות והמדיניות שהתקבלו.
- ניתוח תוצאות: כל חודש הקבוצה מנתחת את התוצאות שהושגו באותו החודש, משווה אותן לתחזיות והיעדים שהוצבו ובוחנת את הפערים שנוצרו.
- שיפור מתמיד: בהתבסס על הממצאים, הקבוצה מבצעת התאמות ושיפורים בתהליך S&OP, ובונה תוכנית אופטימלית יותר לחודש הבא.

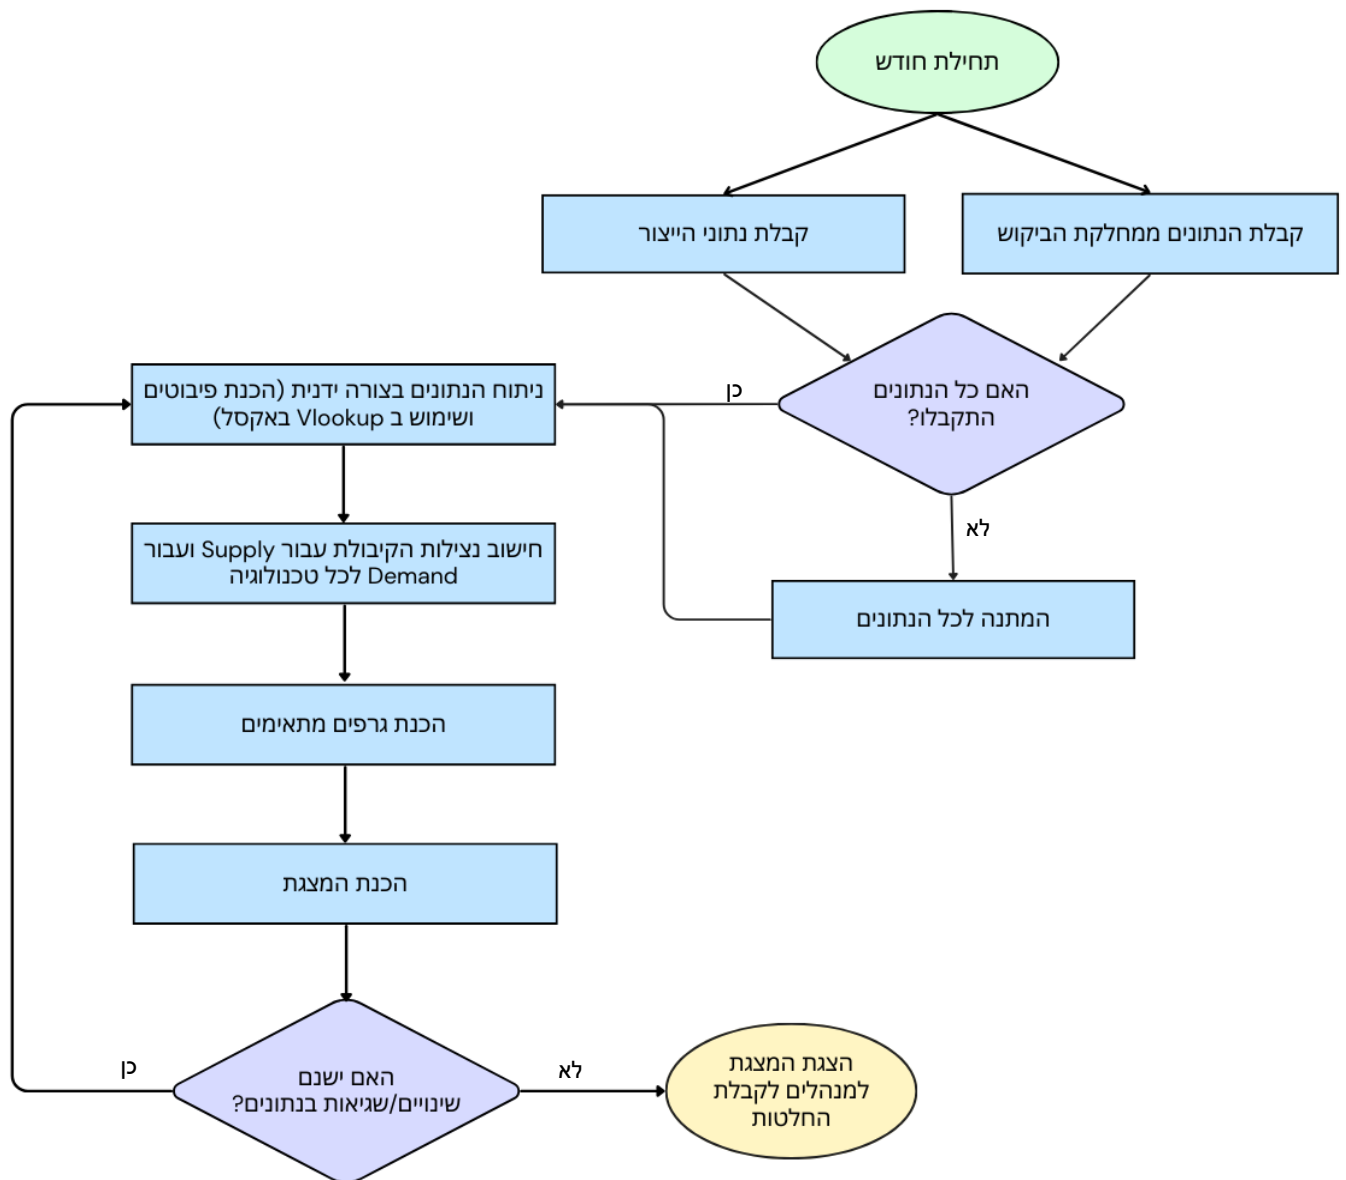
תהליך S&OP של אינטל מהווה מרכיב עיקרי בהבטחת תפעול חלק והצלחה של החברה. באמצעות תהליכים מובנים ומעקב קפדני, הצוות מבטיח שאינטל תגיב במהירות וביעילות לכל שינוי בשוק, תגשים את מטרותיה התפעוליות ותמשיך להוביל בתעשייה.

### 3.3 חשיבות התהליך לאינטל

תהליך S&OP הוא בעל חשיבות רבה עבור חברות גדולות וגלובליות כמו אינטל, אשר פועלות בשוק תחרותי ומתקדם מבחינה טכנולוגית. יישום מוצלח של תהליך זה מאפשר לאינטל:

- להגיב במהירות לשינויים בביקוש- עם תחזיות מדויקות ונתונים מעודכנים, ניתן לבצע התאמות מהירות ולהגיב לשוק המשתנה. תחזיות אלו מאפשרות לחברה לזהות מגמות שוק ולצפות עליות או ירידות בביקוש.
- לנהל טוב יותר את משאבי הייצור- על ידי יישום תחזיות וניתוח נתונים, ניתן לייעל ולמקסם את תפוקת המפעלים ויעילות משאבי הייצור ולהפחית בזבז של חומרי גלם, זמן ומשאבים.
- לייעל את שרשרת האספקה- באמצעות סנכרון בין מחלקות השונות והשגת תמונה כוללת ועדכנית לכל שרשרת האספקה, ניתן לשפר את התהליכים, לצמצם סיכונים ולהבטיח את רציפות הייצור ועמידה במועדי האספקה.

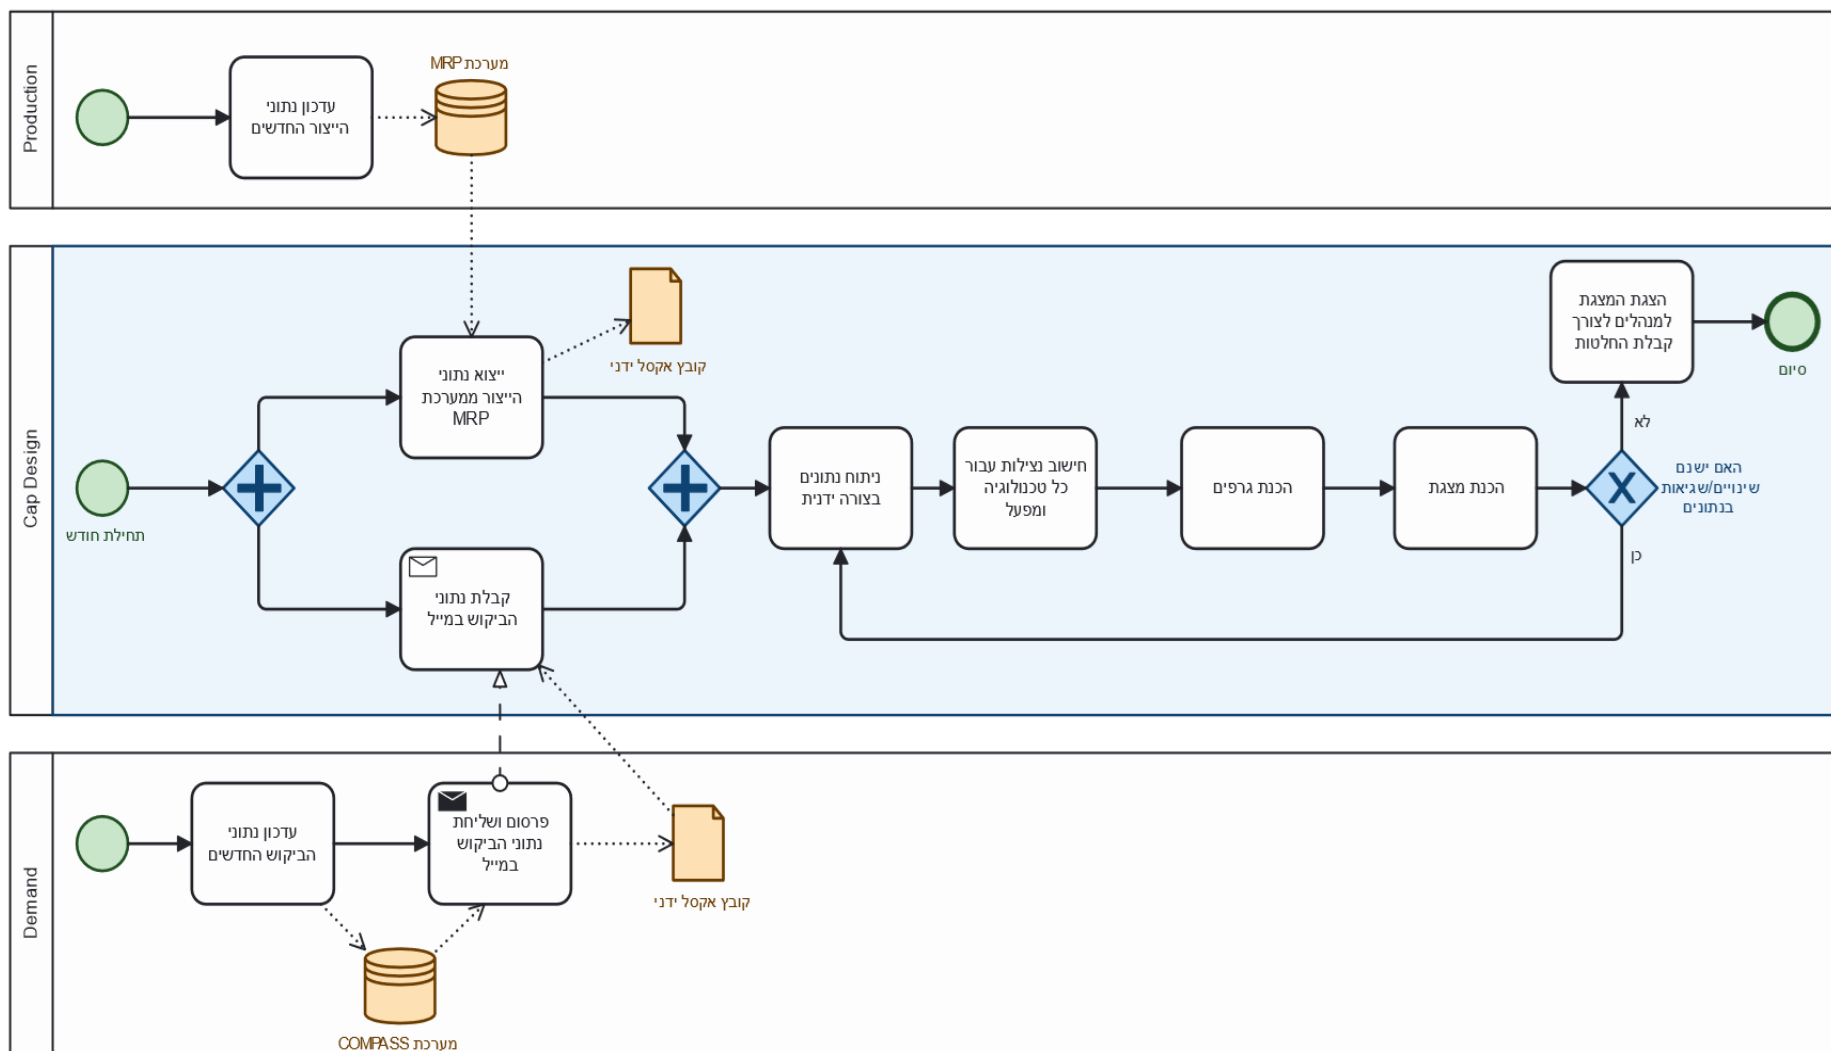
### 3.4. תרשים זרימה



איור 2- תרשים זרימת תהליך ה-S&OP באינטל



### 3.5. תרשים BPMN למצב הקיים




איור 3- תרשים BPMN של תהליך ה-S&OP באינטל

## 4. הגדרת הבעיה

צוות ה-S&OP של אינטל ממלא תפקיד קריטי בהבטחת תיאום בין הביקוש, הייצור והאספקה. עם זאת, התהליך הקיים כיום מתאפיין בבעיות משמעותיות הפוגעות ביעילות ובדיוק, וכתוצאה מכך עשויות להיות לו השלכות שליליות על הביצועים העסקיים של החברה.

### 4.1. בעיה ראשונה: תהליך ידני, איטי עם טעויות אנוש


- תהליך ידני באקסל: נתוני הביקוש מתקבלים ממחלקת ה-Demand כקובץ אקסל ידני שנשלח במייל, ונתוני הייצור מתקבלים כקובץ אקסל ידני ממערכת ה-MRP. ניתוח הנתונים גם מתבצע בצורה ידנית באקסל. תהליך זה קורה בצורה מונוטונית מידי חודש והוא מאוד מייגע, זה יכול לגרום לעיכובים משמעותיים, טעויות אנוש והקטנת דיוק ואמינות הנתונים.
- חסר סנכרון בין המחלקות: מכיוון שהנתונים מתקבלים בזמנים שונים משתי מחלקות שונות, נוצר פער בין זמני קבלת הנתונים מה שגורם לעיכוב תחילת העבודה של הצוות.
- זמן ארוך לתהליך: כיום, תהליך ניתוח הנתונים, בניית התוכנית האסטרטגית והכנת המצגת מרגע קבלת כל הנתונים, לוקח בממוצע כ-6.3 ימי עבודה בכל חודש [ראה גרף 1]. לאחר מכן, הצוות מציג את המצגת לשרשרת מנהלים, כאשר לעיתים, פורומים לקבלת ההחלטות מתקיימים אף כחודש לאחר תחילת התהליך הראשוני. זמן זה מוביל לעיכובים בקבלת החלטות ומוביל לניהול ריאקטיבי במקום ניהול פרואקטיבי.
- מונוטוניות: חלק ניכר מתהליך S&OP מתבצע באותן שיטות שוב ושוב מידי חודש. מונוטוניות זו לא רק מאטה את התהליך, אלא גם מגבירה את סיכון טעויות אנוש ותהליכי עבודה משעממים ופחות אפקטיביים.



גרף 1- מדידת מספר ימי העבודה שלוקח התהליך מידי חודש

## 4.2. בעיה שנייה: חוסר דיוק בתחזית הביקוש

כיום, מחלקת ה-Demand חוזה את הביקושים על ידי חישוב די פשוט, שמורכב מהביקושים לפי חוזים שנסגרו מול הלקוחות + חוזים שעוד לא נסגרו באחוז ביטחון של 90%. המחלקה לא משתמשת בכלים של למידת מכונה ובינה מלאכותית, ולכן תחזיות הביקוש שמתקבלות לחודשים רחוקים יותר הן פחות מדויקות ומצריכות התאמות רבות לאחר מכן. לדוגמה, חיזוי הביקושים שנעשו בחודש ינואר '24 מצביעים על ירידה באחוז הדיוק ככל שהחיזוי לטווח רחוק יותר, בהשוואה לנתוני הביקוש שקרו בפועל בדצמבר '24 [ראה גרף 2]. בגלל תחזיות לא מדויקות, ניסיונות לתכנון ייצור ומלאי באופן יעיל נכשלות, מה שמוביל לפערים שקשה לסגור. במקרים מסוימים, זה יכול להוביל להצטברות מלאי מיותרת או למחסור במוצרים קריטיים.



גרף 2- דיוק נתוני הביקוש לשנת 2024, לפי נתוני הביקוש של חודש ינואר 2024.

בעיות אלו מעמידות את אינטל בפני אתגרים חמורים כמו ניהול ריאקטיבי, חוסר דיוק בתחזיות הביקוש, פגיעה בפרודוקטיביות הצוות ומונוטוניות בתהליכי העבודה. כל אלו מפחיתים את היכולת של אינטל לפעול בצורה מיטבית ולשמור על יתרון תחרותי בשוק. לכן, יש צורך במציאת פתרונות משולבים להאצת תהליכים, שיפור דיוק התחזיות ושיפור הסינכרון בין המחלקות השונות.

## **5. מטרת הפרויקט**

צוות ה-S&OP באינטל ממלא תפקיד קריטי בהבטחת תיאום בין הביקוש, הייצור והאספקה ברחבי העולם. עם זאת, התהליך הנוכחי מאופיין בעבודה ידנית ומונוטונית, חוסר סנכרון בין המחלקות וחוסר דיוק בתחזיות הביקוש. מטרת הפרויקט היא להטמיע מערכת אוטומציה חדשנית (דאשבורד) שתפחית את החולשות הללו, תיעל את העבודה, ותצמצם את הצורך בכוח אדם בתהליכים ידניים. כחלק מהפתרון, יפותח אלגוריתם חיזוי מתקדם על בסיס למידת מכונה, אשר יסייע לשפר את דיוק תחזיות הביקושים.

### **1. השגת אוטומציה וייעול התהליך**

המטרה הראשונה והמרכזית של הפרויקט היא להטמיע מערכת אוטומציה שתאסוף נתונים בצורה אוטומטית, ישירות ממסדי הנתונים השונים של אינטל. תהליך האוטומציה יחליף את התהליך הידני המבוסס על קבצי אקסל ושיתוף מידע במיילים. המערכת תבצע את ניתוח הנתונים באופן מיידי בלחיצת כפתור, מה שיאפשר לצוות ה-S&OP לפנות זמן רב למשימות אסטרטגיות יותר. כחלק מהאוטומציה, הפרויקט יפחית את ההסתמכות על תהליכים ידניים, אשר נוטים להיות רגישים לטעויות אנוש. באמצעות מערכות אוטומטיות וחיזוי מתקדם, נבטיח שיפור בתהליכי העבודה ונמנע טעויות שהתגלו קודם לכן.

### **2. פיתוח אלגוריתם חיזוי מתקדם לצורך דיוק תחזיות הביקוש**

המטרה השנייה היא פיתוח אלגוריתם חיזוי מתקדם אשר יתבסס על נתוני עבר ויזהה מגמות עכשוויות ועתידיות של הביקושים בצורה מדויקת. מודל החיזוי המתקדם ישפר באופן משמעותי את דיוק תחזיות הביקוש למוצרים השונים של אינטל ויצמצם את הפערים בין התחזיות לביקושים בפועל. שיפור זה יאפשר לאינטל לנצל את המשאבים בצורה מיטבית ולתכנן את הייצור והאספקה בצורה מדויקת יותר.

### **3. האצת תהליך קבלת ההחלטות**

המטרה האחרונה היא לקצר משמעותית את הזמן הנדרש להכנת המצגות הניהוליות. כיום, הזמן שלוקח מרגע קבלת הנתונים ועד להצגת המצגת בפני כל מנהלי החברה הוא כחודש בממוצע. בעזרת אוטומציה של תהליך איסוף, עיבוד וניתוח הנתונים, ניתן יהיה לקצר את פרק הזמן זה, מה שיאפשר קבלת החלטות ניהוליות מהירות ומושכלות יותר.

## 5.1. מדדי הערכה

באמצעות מדדי הערכה אלה, נוכל להעריך את התועלת שמביאה המערכת האוטומטית ואת האפקטיביות של האלגוריתם החיזוי המתקדם בפרויקט. המדדים מספקים תמונה מקיפה של היתרונות הפוטנציאליים וכיצד הם תורמים לשיפור בתהליכי העבודה והביצועים הכלליים של הארגון.


### זמן עיבוד נתונים - שיפור זמן עיבוד הנתונים:

- מצב נוכחי- מדדנו את הזמן שלוקח תהליך איסוף וניתוח הנתונים הידני (מרגע קבלת הנתונים ועד שהמצגת מוכנה) לוקח בממוצע כ-6.3 ימי עבודה [ראה גרף 1].
- תחזית לאחר סיום הפרויקט- צפי לחיסכון מלא של זמן איסוף וניתוח הנתונים (0 ימי עבודה). בעזרת אוטומציה של התהליך ניתן יהיה להתחבר ישירות למסדי הנתונים השונים באינטל, ולבצע את ניתוח הנתונים בלחיצת כפתור.


### דיוק תחזיות - שיפור אחוז דיוק התחזיות:

- מצב נוכחי- אספנו את נתוני הביקוש החודשיים עבור שלוש טכנולוגיות שונות של אינטל על פני חמש שנים (2020-2024), חישבנו את אחוז השגיאה הממוצע (MAPE) של חיזוי הביקוש לעומת הנתונים בפועל: טכנולוגיה 1: 11.25%, טכנולוגיה 2: 38.25%, טכנולוגיה 3: 28.5%.
- תחזית לאחר סיום הפרויקט- המטרה היא לשפר אחוז השגיאה הממוצע של כל טכנולוגיה בכ-5%, בעזרת מודל למידת מכונה שיתבסס על נתוני עבר אלו.


#### Process 1:



#### Process 2:



#### Process 3:



גרפים 3,4,5- הביקושים בפועל עבור כל טכנולוגיה לעומת חיזוי הביקוש כפי שנעשה בינואר 24, כולל אחוז השגיאה הרבעוני.

## **יעילות עבודה - צמצום כוח האדם:**

- **מצב נוכחי-** כיום כ-4 מהנדסים עובדים על ניתוח הנתונים והכנת המצגת. העבודה מצריכה זמן ומאמצים משמעותיים עקב תהליכים ידניים, כגון איסוף נתונים, חישובים ויצירת גרפים.
- **תחזית לאחר סיום הפרויקט-** עם ההטמעה של מערכת אוטומטית, המערכת תטפל באיסוף, עיבוד והצגת הנתונים באופן עצמאי. התוצאה היא שהמספר הדרוש לשם תפעול התהליך ירד לאפס או יצריך פיקוח קל של מהנדס אחד בלבד. המהנדסים שיתפנו יכולים לנצל את זמנם למשימות אסטרטגיות ויצירתיות יותר, כגון פיתוח תהליכי שמירה על יתרון תחרותי והמצאת פתרונות טכנולוגיים.

## **הפחתת טעויות אנוש**

- **מצב נוכחי-** הידניות בתהליך ניתוח הנתונים מקנה סיכון משמעותי לטעויות אנוש. המהנדסים העידו בסקר [ראה נספח 1] כי הם מזהים בממוצע כשלוש טעויות בחודש, מה שמשפיע לרעה על אמינות הדיווחים ועל קבלת ההחלטות.
- **תחזית לאחר סיום הפרויקט-** מערכת אוטומטית תהפוך את כל תהליך ניתוח הנתונים לחסר טעויות ידניות. התהליכים האוטומטיים מפחיתים את החשיפה לפעולות שעלולות לגרום לטעויות ומעלים את רמת הדיוק והאמינות של המידע שהמערכת מספקת. זה ייתן למקבלי ההחלטות בטחון גבוה יותר בהחלטות שהם מקבלים.

## **קבלת החלטות- צימצום הזמן עד להצגת המצגת לשרשרת המנהלים.**

- **מצב נוכחי-** המהנדסים העידו בסקר [ראה נספח 1] שכיום לוקח בממוצע כחודש מרגע קבלת הנתונים ועד הצגת המצגת לכלל המנהלים בכל השרשרת הארגונית.
- **תחזית לאחר סיום הפרויקט-** עקב צמצום זמן ניתוח הנתונים בכשבוע, ניתן יהיה להציג את המצגת לכלל המנהלים עד לכ-3 שבועות. יתרה מכך, המנהלים יקבלו גישה לשקיפות מלאה בזמן אמת לכל הנתונים, מה שיאפשר להם לחוש ולזהות שינויים בשוק באופן מיידי ולשפר את יכולותיהם בקבלת החלטות.

## 5.2. אילוצים פנימיים וחיצוניים בהטמעת הפתרון בארגון

בעת תכנון והטמעת מערכת האוטומציה בארגון, יש לקחת בחשבון את האילוצים הפנימיים והחיצוניים שעשויים להשפיע על תהליך ההטמעה. באמצעות הבנה מעמיקה של האילוצים ומציאת פתרונות מותאמים, ניתן להבטיח התקדמות פרויקט חלקה ויעילה, תוך מזעור הסיכונים.

### אילוצים פנימיים

#### 1. זמן מוגבל:

- האילוץ: הפרויקט כפוף ללוחות זמנים אקדמיים ואילוץ מילואים של חברי הפרויקט.
- הפתרון: תכנון מועדי ביצוע ברורים, עמידה בלוח הזמנים לפי תרשים גאנט, חלוקת משימות קבוצתית יעילה וניהול זמנים נכון.

#### 2. גישה למידע רגיש:

- האילוץ: נתוני הביקוש והייצור באינטל הם נתונים רגישים וחסיים. כאקדמאים חיצוניים לארגון, ישנה הגבלת גישה לנתונים אלו.
- הפתרון: חתימה על הסכמי סודיות ושימוש בנתונים פיקטיביים לצורך האב טיפוס למערכת.
- 3. אינטגרציה עם מערכות אינטל הקיימות:

- האילוץ: הצורך בשילוב המערכת החדשה עם מערכות מידע קיימות עשוי להוות אתגר.
- הפתרון: לצורך אב טיפוס המערכת, יעשה שימוש בקבצי אקסל. בשלב הטמעת המערכת בארגון, נעזר בחברת הקבוצה שעובדת בארגון על מנת להתחבר למערכות אינטל.

### אילוצים חיצוניים

#### 1. התנגדות לשינוי:

- האילוץ: עובדים עשויים להתנגד לשינוי בתהליכים אליהם הם רגילים.
- הפתרון: מעורבות המהנדסים משלב התכנון ועד לשלב היישום, שיתוף פעולה ודיווחים שוטפים.

#### 2. שינויים בדרישות המהנדסים:

- האילוץ: שינויים בצרכים או בדרישות מצד מהנדסי אינטל במהלך הפרויקט.
- פתרון: גמישות בתכנון הפרויקט ועדכונים מתמידים עם הלקוח, תוך תיאום ציפיות מראש.

## 6. תרשים גאנט

	2024			2025							
	אוקטובר	נובמבר	דצמבר	ינואר	פברואר	מרס	אפריל	מאי	יוני	יולי	אוגוסט
הגשת הצעת הפרוייקט											
חקר המצב הקיים											
איסוף וניתוח הנתונים											
כתיבת דוח ביניים											
בניית מודל החיזוי											
הרצת המודל ואימות הנתונים											
בניית הדאשבורד											
הטמעה בארגון											
כתיבת דוח סיכום											

סמטר א'

סמטר ב'

איור 4- תרשים גאנט חודשי



## 7. סקר ספרות

במסגרת פרויקט הגמר, נסקרה ספרות מחקרית רלוונטית. הסקירה מתמקדת במאמרים מרכזיים המתארים את חשיבות תהליך ה-S&OP, אוטומציה של תהליכים ידניים, גורמי ההצלחה בהטמעת מערכת אוטומציה, מדדי הערכת מודלים וכן התאמת אלגוריתמי חיזוי. מאמרים אלו מספקים תובנות מבוססות מחקר, המסייעות בגיבוש הפתרונות שיוטמעו בפרויקט.

### מאמר 1- שיפור תפוקה ורווחיות באמצעות תכנון S&OP

Islam Rafiquel [1] התמקד בשיפור הרווחיות והפרודוקטיביות של ארגונים תעשייתיים באמצעות יישום יעיל של S&OP. המאמר מדגים כיצד תכנון אפקטיבי של תהליכי המכירות והתפעול מאפשר:

- התאמה טובה יותר לביקוש
- שיפור היכולת להגיב במהירות לשינויים בשוק
- צמצום עלויות ייצור ולוגיסטיקה

מאמר זה תורם לפרויקט שלנו משמעותית, שכן הוא מחזק את ההנחה כי יישום מתודולוגיית S&OP משופר יוכל להביא ליעול תהליכים, קבלת החלטות מבוססות נתונים, ולמיקסום הרווחיות של הארגון. בנוסף לכך, המאמר מספק תובנות וכלים חיוניים לקבלת החלטות יעילה, אשר יסייעו לנו להבין אילו נתונים דרושים למנהלים על מנת לקבל החלטות מושכלות.

המידע וניתוחי המקרה המתוארים במאמר יוכלו לשמש כבסיס לפיתוח ממשק דאשבורד יעיל, שיאפשר למנהלים לצפות ולנתח נתוני ביצועים בזמן אמת. כך, נוכל לבנות את הדאשבורד בצורה שתספק נתונים ברורה וממוקדת, תגיב במהירות לשינויים בשוק ותראה אפשרויות לשיפור ההתאמה לביקוש וצמצום עלויות ייצור.

---

### מאמר 2- אוטומציה בתהליכי ניהול שרשרת האספקה

המאמר של Kalluri [2] מתמקד בהשפעת אוטומציה תהליכית של חברת Pega על ניהול שרשרת האספקה. המאמר מדגיש כיצד שימוש ב-RPA (Robotic Process Automation) מוביל לשיפור משמעותי בביצועים, בין היתר:

- הפחתה של 40% בזמני העיבוד
- ירידה של 85% בשגיאות ידניות
- צמצום עלויות תפעוליות בכ-30%

ממצאים אלו תומכים באופן ישיר ברעיון המרכזי של הפרויקט: יישום אוטומציה בתהליך S&OP לשיפור ביצועים. שימוש במערכת BI אוטומטית בדומה לשימוש ב-RPA שנעשה במאמר כתחלופה לתהליכים ידניים, יכול להפחית את זמן העבודה של המהנדסים, לצמצם את השגיאות הידניות ולשפר את היעילות הארגונית הכוללת.

---

### מאמר 3- גורמי הצלחה קריטיים ביישום מערכות BI

Yeoh ו-Koronios [3] מנתחים את הגורמים הקריטיים להצלחת יישום מערכות BI בארגונים גדולים. המאמר שלהם מציג מספר היבטים מרכזיים המשפיעים על הצלחת יישום מערכות מסוג זה, ביניהם:

- מחויבות הנהלה בכירה לתהליך
- הגדרת צרכים עסקיים ברורים
- שילוב טכנולוגיות מתקדמות והתאמה לתהליכים קיימים
- הכשרה ותמיכה למשתמשים

הסקירה מצביעה על כך שללא תכנון נכון של גורמים אלו, יישום מערכות BI עלול להיכשל. ממצאים אלו רלוונטיים במיוחד לפרויקט, שכן הם מספקים מסגרת עבודה להטמעת פתרון BI, תוך התמקדות בגורמי הצלחה קריטיים שיבטיחו תוצאות אופטימליות.

---

### מאמר 4- שימוש במודלים שונים של למידת מכונה לצורך חיזוי, ובחירת המודל האופטימלי

המאמר של Nafis A. [4] עוסק בניבוי רמות אנרגיה של חומרים שונים לתאים סולאריים באמצעות כריית נתונים ולמידת מכונה. הוא מתאר שימוש באלגוריתם Lazy Predict לבחינת מעל 40 אלגוריתמים שונים ולבחירת המודל הטוב ביותר לניבוי:

1. **הזנת הנתונים**- המודל דורש קלט בצורת שני סטים של נתונים: משתני הקלט ( $X$ ) ותגיות המטרה ( $y$ ).
2. **ביצוע חישובים**- מודל ה-Lazy Predict מחלק את הנתונים לסט האימון וסט הבדיקה, ומריץ מספר רב של אלגוריתמים על הנתונים הללו. הוא משתמש במתודולוגיה מובנית כדי לבצע חישוב מהיר של ביצועים. עבור רגרסיה, משתמשים ב-LazyRegressor.

3. **תוצאות ודירוג** - לאחר הרצת המודלים, הספרייה מחזירה טבלה של ביצועי המודלים השונים. טבלה זו כוללת מדדים כמו: accuracy, ROC AUC, F1 Score ועוד. עבור גרסיה המודל מציג מדדים כמו: MSE, RMSE,  $R^2$ , MAE.

ממצאי המאמר מצביעים על כך שהמודל Random Forest הוא האופטימלי ביותר לפי המדדים, בשל יכולת החיזוי הגבוהה שלו, עם פערים קטנים בין הערכים החזויים לערכים בפועל. בהתבסס על תובנות אלו, ניתן ליישם גישה דומה בפרויקט לצורך שיפור חיזוי הביקושים בתהליך S&OP. השימוש בכלי כמו Lazy Predict יאפשר השוואה אוטומטית בין מודלים שונים, ויסייע בבחירת האלגוריתם האופטימלי לתהליך החיזוי.

## **מאמר 5- מדידת הצלחת יישום מודל חיזוי מבוסס למידת מכונה**

Kim ו-Sehoon [5] מציגים כיצד שימוש במודלים של למידת מכונה יכול לשפר מערכות חיזוי ביקושים בארגונים תעשייתיים, תוך התמקדות בתחום הרכב. המאמר מדגיש את חשיבות השימוש בניתוח נתונים וחיזוי מתקדם ככלי לשיפור תהליכי קבלת החלטות בשרשרת האספקה. על פי המחקר, חיזוי ביקושים מבוסס למידת מכונה מאפשר:

- שיפור משמעותי בדיוק התחזיות, תוך צמצום שגיאות חיזוי.
- יעול תהליכי קבלת החלטות על בסיס נתונים, במקום הסתמכות על הערכות ידניות.
- הפחתת חוסר ודאות בתכנון אספקה והקצאת משאבים.

הצלחת יישום מודל חיזוי מבוסס למידת מכונה יכולה להימדד ע"י אינדיקטורים כמותיים:

1. דיוק תחזיות (Forecast Accuracy) – מדד להערכת רמת ההתאמה בין התחזיות שהופקו על ידי המערכת לבין הנתונים בפועל. המדדים המקובלים הם:
  - Mean Absolute Percentage Error (MAPE) – חישוב ממוצע אחוזי השגיאה בין הערכים החזויים לערכים האמיתיים.
  - Root Mean Square Error (RMSE) – מדד לרמת הסטייה הכוללת בתחזיות.
2. שיפור בזמן התגובה – הפחתה במשך הזמן הנדרש לעיבוד וניתוח נתונים, בפרט בתהליך חישוב תחזיות הביקושים, דבר שמאפשר קבלת החלטות מהירה יותר.
3. רמת אינטגרציה ארגונית – אחוז המשתמשים בתחזית המודל בארגון והשפעת המידע על תהליכי קבלת החלטות.
4. זיהוי משתנים קריטיים באמצעות RRelief – המאמר מדגיש את השימוש ב-RRelief, אלגוריתם שמטרתו להעריך את חשיבות התכונות (features) במודלים של למידת מכונה.

באמצעות שימוש ב-RRelief ניתן לקבוע אילו משתנים תורמים באופן המשמעותי ביותר לשיפור דיוק החיזוי.

המדדים שנמצאו במאמר יכולים לשמש להערכת הצלחת מודל החיזוי בפרוייקט. שילוב מדדים אלו, לצד הגורמים הקריטיים להצלחה שזוהו במאמרים הקודמים, יאפשר לבחון באופן מדעי ומדויק כיצד השפיעו מודל החיזוי מבוסס למידת מכונה ומערכת ה-BI על ביצועי תהליך ה-S&OP באינטל. בנוסף, ניתן ליישם את השימוש ב-RRelief כדי לזהות אילו משתנים (כגון זמני ייצור, נתוני מלאי, ומגמות ביקוש) הם בעלי ההשפעה הגבוהה ביותר על איכות התחזיות, ולהתאים את המודל כך שיתמקד במשתנים הקריטיים ביותר ולהוביל לאופטימיזציה נוספת של המערכת ולשיפור דיוק התחזיות.

## מאמר 6: מדדי הערכת מודלים רגרסיביים

Brandon [6] מציע גישה מקיפה לבחינת ביצועים של מודלים רגרסיביים על ידי שימוש במדדים סטטיסטיים המתארים את איכות התחזיות ביחס לנתוני אמת. המאמר מהווה בסיס תיאורטי חשוב בבניית מערכות חיזוי מדויקות, במיוחד בפרויקטים עסקיים שבהם דיוק התחזיות משפיע ישירות על תהליכי תפעול וקבלת החלטות. המאמר מפרט חמישה מדדים עיקריים, שכל אחד מהם מספק זווית שונה על ביצועי המודל:

- **R-Squared**: מדד המציין את אחוז השונות שבנתוני המטרה שהמודל הצליח להסביר. מדד גבוה מעיד על התאמה טובה יותר לנתונים היסטוריים. חשוב לשים לב שהמדד אינו מבדיל בין הסבר "אמיתי" לבין רעש או עודף התאמה.
- **Adjusted R-Squared**: משדרג את R-Squared על ידי שילוב מספר המשתנים במודל ומניעת עלייה מזויפת בדיוק התחזיות שנובעת מתוספות בלתי מועילות של משתנים.
- **MSE (Mean Squared Error)**: מייצג את ממוצע ריבועי השגיאות בין התחזיות לנתונים בפועל, רגיש לשגיאות גדולות ואינו מתאים לסטיות קיצוניות.
- **RMSE (Root Mean Squared Error)**: מתאר את השורש של MSE, מחזיר את הערכים ליחידות המקור של הנתונים, ומאפשר הבנה ניהולית ומבצעית טובה יותר.
- **MAE (Mean Absolute Error)**: מחשב את ממוצע השגיאות האבסולוטיות ומספק ניתוח יציב יותר, בניגוד ל-MSE ו-RMSE שאינם פרופורציונליים לסטיות גדולות.

המאמר מדגיש את החשיבות של שימוש בשילוב מדדים כדי להתאים לנתונים ולדרישות העסקיות השונות. במסגרת פרויקט הגמר, שמטרתו לשפר את תהליך ה-S&OP באינטל באמצעות אוטומציה, BI ומודלים של חיזוי ביקושים, נעשה שימוש במדדים אלו ככלי מרכזי להשוואה בין מודלים ולהערכת התאמתם לסביבות עסקיות שונות. המדדים מאפשרים למפות את יכולות ההסבר של המודל ולבחון

את השפעת הוספת משתנים חדשים. לדוגמה:

**R-Squared ו- Adjusted R-Squared** - מציגים יכולת המודל להסביר את התנודתיות בביקושים

ואת השפעת משתנים נוספים כגון עונתיות או מגמות גלובליות.

**RMSE ו- MAE** - מציעים מדידה כמותית בשגיאות מוחשיות להערכת מודלים במסגרת הפרויקט,

בעוד שמדד MAE מספק תובנות באחוזים על הפער היחסי.

שילוב של המדדים מאפשר קביעת רמת דיוק רצויה לכל קטגוריה מוצרית, כמו תחזית עם MAPE של

פחות מ-10% שתיחשב כמדויקת למוצרים יציבים.

## 7.1. תובנות מסקר הספרות

הסקירה הספרותית שבוצעה במסגרת הפרויקט מספקת הבנה מעמיקה של האמצעים לשיפור תהליך

ה-S&OP באינטל תוך שילוב אוטומציה BI, ומודלי חיזוי מתקדמים. תחילה, המאמר של Islam

Rafiquel [1] מדגים את היתרונות שבתכנון אפקטיבי לתהליך ה-S&OP ואיך שיטה זו יכולה להוביל

לשיפור ברווחיות ובפרודוקטיביות הארגון. הבנה זו מדגישה את החשיבות של יישום מתודולוגיית

S&OP משופרת אשר תוכל לתמוך ביכולות הארגוניות של אינטל.

בהמשך, המאמר של Kalluri [2] מתמקד בתרומות חיוביות של אוטומציה תהליכית בניהול שרשרת

האספקה, עם דגש על הפחתת טעויות ידניות ושיפור דיוק תהליכי קבלת ההחלטות. זה מוכיח כיצד

הטכנולוגיה יכולה להשפיע על ביצועים ארגוניים ולספק תחזיות מדויקות יותר.

מערכות BI אף הן זוכות לניתוח מעמיק במאמר של Yeoh & Koronios [3], שבו מתארים המחברים

את הגורמים הקריטיים להצלחה ביישום מערכות מסוג זה. אסטרטגיות יישום יעילות מאפשרות

הטמעת פתרונות מבוססי נתונים שמובילים לשיפור אמינות התחזיות.

בנוסף, המאמר של Nafis A. [4] מדגיש את השימוש במודלים של למידת מכונה לשיפור דיוק תחזיות

עם כלים מתקדמים כגון Lazy Predict, המסייעים בבחירה של המודל האופטימלי.

יתרה מכך, המאמר של Kim & Sehoon [5] משלים את התמונה על ידי הדגשת היתרון שבניתוח

נתונים וחיזוי מתקדם לשיפור תחזיות והאינטגרציה הארגונית.

בסופו של דבר, המאמר של Brandon [6] מוביל אותנו לתובנה לגבי מדדי הערכת מודלים

גרגסיביים. באמצעות מדדים כמו R-Squared, Adjusted R-Squared, MSE, RMSE ו-MAE-

ניתן לנתח את איכות התחזיות ביחס לנתוני אמת באופן שמאפשר הבנה מעמיקה של הביצועים, תוך

שילוב מספר מדדים להבטחת הצלחה בתהליך החיזוי העסקי.

לסיכום, הסקירה הספרותית מספקת תובנות וכלים חיוניים להטמעת פתרונות מבוססי נתונים לשיפור

ביצועי הארגון, תוך שימת דגש על תכנון אפקטיבי, אוטומציה תהליכית, שימוש במערכות BI ולמידת

מכונה, שכולם ביחד מגבירים את יכולת הארגון להגיב לשינויים בשוק בצורה יעילה ומדויקת יותר.

## 8. מתודולוגיה

### 1. חקר המצב הקיים

א. מיפוי תהליכים נוכחיים:

- הבנה ותיאור של האופן שבו מתבצע כיום תהליך העבודה.
- תיעוד של זרימת העבודה הנוכחית, כולל תרשימי זרימה ותיעוד עבודה ידנית.
- סקר בקרב צוות המהנדסים ואיתור בעיות ושגיאות החוזרות על עצמן.
- זיהוי שלבים בתהליך הנוכחי שבהם יש חוסר יעילות.

ב. איסוף נתונים:

- איסוף נתוני הייצור, האספקה והביקוש מהשנים האחרונות כדי להבין מגמות היסטוריות וביצועים נוכחיים. (עקב המגבלות ינתנו לצורך הפרוייקט נתונים פקטיביים)
- תיעוד המדדים הקיימים בארגון, כגון זמני עיבוד, דיוק תחזיות ושגיאות אנוש.

### 2. איסוף דרישות

א. זיהוי צרכים עסקיים:

- קיום סקר [ראה נספח 1] ראיונות ופגישות עם אנשי הצוות להבנת הדרישות העסקיות.
- זיהוי הצרכים התפעוליים, כגון הגברת היעילות, הפחתת טעויות אנוש ושיפור תחזיות.

ב. דרישות מערכת:

- הגדרת הפונקציות הבסיסיות שהמערכת החדשה צריכה לכלול (למשל: איסוף נתונים אוטומטי, יכולת ניתוח נתונים, ויזואליזציה).
- הגדרת דרישות טכניות שקשורות לביצועים, זמני עיבוד, שינויים במערכת הקיימת ואינטגרציה.
- כתיבת מסמך דרישות [ראה נספח 2] מפורט שיתאר את כל הדרישות הפונקציונליות והלא פונקציונליות.
- קבלת אישור מבעלי עניין מרכזיים על מסמך מתועד לפני שעוברים לשלב הבא.

### 3. עיבוד הנתונים

- ניקוי וטיהור הנתונים מאי-דיוקים, כפילויות וחוסרים.
- יצירת דוחות בסיסיים וגרפים שיוכלו לסייע באבחון ראשוני של הנתונים.
- פילוח המידע לפי קטגוריות שונות כגון סוג מוצר, טכנולוגיה, תקופות שונות.

#### **4. תכנון ובניית מודלי חיזוי ומערכת BI**

א. בחירת מודלים:

- בחירה במודלים סטטיסטיים ובמודלי למידת מכונה המתאימים ביותר, כמו מודלים לינאריים, עצי החלטה, מודלים עונתיים ועוד.
- בחינת האלגוריתמים על נתונים היסטוריים כדי לבדוק דיוק ועמידות, והערכת האלגוריתמים.

ב. פיתוח מודלים:

- כתיבת הקוד והטמעת האלגוריתמים שנבחרו.
- למידה מתוך נתוני העבר לבדיקת התוצאות ושיפורים.

ג. פיתוח מערכת BI:

- הקמת התשתית הדרושה לניתוח נתונים ולבניית Dashboards.
- בנייה ופיתוח מערכת ה-BI על בסיס הדרישות שנאספו.

#### **5. הטמעת המערכת ולימוד המשתמשים**

א. תהליך ההטמעה:

- הכנסת המערכת לשימוש באופן הדרגתי בהתאם לשלבים מתוכננים מראש.
- חיבור המערכת עם מערכות אינטל השונות.
- מתן תמיכה בזמן אמת למשתמשים, זיהוי בעיות בזמן אמת ותיקונן.

ב. לימוד והכשרת משתמשים:

- הכשרת המשתמשים במערכת החדשה.
- יצירת מדריכים כתובים והדרכות המתארות את השימוש במערכת.

#### **6. בחינת המערכת ע"פ מדדי הערכה**

א. מדדי הערכה:

- מדידת דיוק התחזיות במערכת החדשה בהשוואה לתחזיות הקודמות.
- מדידת הזמן המושקע בעיבוד הנתונים ובדיקת חיסכון הזמן הנובע מהאוטומציה.
- מדידת שיפור היעילות בעבודה והפחתת הצורך בכוח אדם.

ב. משוב ושיפור מתמשך:

- בחינת המשוב של המשתמשים כדי להבין את השיפורים הנדרשים.

## 9. הצגת חלופות

לצורך הפרוייקט, בחנו מספר חלופות אפשריות לפתרון, והגדרנו ביחד עם המהנדסים את הקריטריונים עם משקלי החשיבות. הענקת הציונים לכל חלופה התבססה על מומחיות ודעת הצוות.

### קריטריונים להערכת החלופות

1. ויזואליזציה של הנתונים: איכות היצוג הגרפי והיכולת להפיק דוחות ודאשבורדים אינטראקטיביים.
2. תמיכה בקבלת החלטות ואמינות הנתונים: יכולת התחברות למסדי נתונים שונים על מנת לספק מידע אמין ומדויק שמסייע בתהליכי קבלת ההחלטות.
3. אינטגרציה עם מודלי Python: גמישות ויכולת המערכת להריץ ולהשתמש בסקריפטים של Python עבור מודל החיזוי.
4. קלות יישום וחווית המשתמש: ידידותיות למשתמש והקלות שבה ניתן ליישם ולהשתמש במערכת.
5. עלות הפיתוח והתחזוק: עלות כוללת של פיתוח המערכת ותחזוקתה.
6. שמירת נתונים היסטוריים: יכולת המערכת לשמור ולהשתמש בנתונים היסטוריים בצורה מסודרת ונגישה.

### חלופות אפשריות:

1. Power BI
2. Excel with VBA
3. Python - Web Application

### טבלת קריטריונים ומשקלים:

קריטריון	משקל	דאשבורד POWER BI	דוח אוטומטי Excel + VBA	Python - Web Application
ויזואליזציה של הנתונים	30%	10	6	8
תמיכה בקבלת החלטות ואמינות הנתונים	20%	9	7	9
אינטגרציה עם מודלי Python	20%	7	7	10
קלות היישום וחווית המשתמש	10%	9	5	8
עלות הפיתוח והתחזוק	10%	8	7	7
שמירת נתונים היסטוריים	10%	9	7	8
ציון משוקלל		8.8	6.5	8.5

טבלה 1- קרטקיונים ומשקלים לחלופות



## **Power BI:**

1. ויזואליזציה של הנתונים (10): מציע מגוון רחב של גרפים ודאשבורדים אינטראקטיביים שמספקים ייצוג גרפי עשיר ומדויק.
2. תמיכה בקבלת החלטות ואמינות הנתונים (9): ניתן להתחבר ישירות למקורות נתונים שונים ומאפשר עיבוד נתונים מובנה של Microsoft, מה שמספק נתונים אמינים ומדויקים.
3. אינטגרציה עם מודלי פייתון (7): תומך בהרצת סקריפטים של Python בצורה חלקה.
4. קלות יישום וחווית המשתמש (9): ידוע כממשק ידידותי למשתמש וקל לתפעול.
5. עלות הפיתוח והתחזוק (8): עלות נמוכה יחסית למערכות אחרות.
6. שמירת נתונים היסטוריים (9): אינטגרציה טובה עם מאגרי מידע לשמירת נתונים היסטוריים.

## **Excel with VBA:**

1. ויזואליזציה של הנתונים (6): מציע כלים בסיסיים יחסית ליצירת גרפים ודאשבורדים, יותר מוגבל מבחינת אינטראקטיביות.
2. תמיכה בקבלת החלטות ואמינות הנתונים (7): הרבה תלוי במבנה גיליונות הנתונים ובסקריפטים הנכתבים, גישה לעריכת נתונים יכולה לגרום לטעויות.
3. אינטגרציה עם מודלי פייתון (7): עבודה עם Python אפשרית אך מורכבת ולא חלקה.
4. קלות יישום וחווית המשתמש (5): כלי ידוע ומוכר מאוד, אך פחות אינטואיטיבי לתהליכי אוטומציה מורכבים.
5. עלות הפיתוח והתחזוק (7): עלות נמוכה יחסית, אך עם עלויות תחזוקה עקב הצורך בגיוס כוח אדם ממומחה ב-VBA.
6. שמירת נתונים היסטוריים (7): אפשרות אך דורשת תחזוקה ידנית מתמידה.

## **Python - Web Application:**

1. ויזואליזציה של הנתונים (8): פייתון מציע כלים חזקים ליצירת ויזואליזציות כמו Matplotlib ו-Seaborn, אך דורש תכנות מתקדם.
2. תמיכה בקבלת החלטות ואמינות הנתונים (9): נתמך היטב ויכולת ליצור מודלים מתקדמים.
3. אינטגרציה עם מודלי פייתון (10): ייחודיות במימוש האלגוריתמים והמודלים המתקדמים.
4. קלות יישום וחווית המשתמש (8): דורש ידע נרחב בתכנות, פחות ידידותי למשתמשים לא טכניים.
5. עלות הפיתוח והתחזוק (7): עלות פיתוח ותחזוקה נמוכה יחסית, בעיקר אם יש כוח אדם מומחה בפייתון.
6. שמירת נתונים היסטוריים (8): יכולת גבוהה אך מחייבת עבודה משמעותית בתכנות להתממשקות עם מסדי נתונים.

### הנמקה לפתרון הנבחר:

**Power BI** נבחרה כחלופה האופטימלית הודות ליתרונות רבים בתחומים כמו ויזואליזציה מתקדמת, תמיכה בקבלת החלטות ואמינות הנתונים, אינטגרציה חלקה עם Python, קלות יישום וחווית משתמש טובה. נוסף לכך, עלות הפיתוח והתחזוקה נמוכה יחסית והכלי מציע גם אפשרויות לשמירת נתונים היסטוריים בצורה נוחה. כל אלו יחד מספקים מערכת מקיפה ויעילה לצרכים הייעודיים של תהליך S&OP באינטל.

באופן זה, Power BI מביאה ערך רב יותר מכלל הבחינות, כפי שמודגם בציון המשוקלל הגבוה ביותר בטבלה (8.8 לעומת 6.5 ב-Excel עם VBA ו-8.5 עם Python)

## 10. מימוש הפתרון: ניסויים, בדיקות וממצאים

החלק המרכזי של הפרויקט התמקד בשני היבטים עיקריים לשיפור תהליך ה-S&OP באינטל: הטמעת מערכת אוטומטית באמצעות דאשבורד, ופיתוח אלגוריתם מתקדם לחיזוי הביקוש.

### 10.1. בעיה ראשונה: תהליך ידני ואיטי. הפתרון: אוטומציה וייעול התהליך בעזרת דאשבורד

#### 1. הגדרת מטרות ודרישות

- **מטרות עסקיות:** הדאשבורד נועד לשפר את דיוק תהליך ה-S&OP באינטל באמצעות אוטומציה. המטרה היא לשפר את תחזיות הביקוש, להפחית טעויות אנוש, ולייעל את תהליך קבלת ההחלטות.
- **דרישות פונקציונליות:** איסוף נתונים אוטומטי, ויזואליזציות אינטראקטיביות, הצגת מידע היסטורי, חיבור למודלי חיזוי מבוססי למידת מכונה. [ראה נספח 2].

#### 2. איסוף ועיבוד נתונים

- **חיבור למקורות נתונים:** בשלב הראשוני השתמשנו בקבצי אקסל ידניים: נתוני ביקוש חודשיים עבור שלוש טכנולוגיות שונות של אינטל על פני חמש שנים (2020-2024), ולאחר מכן לדאשבורד תהיה אפשרות חיבור באופן ישיר למסדי הנתונים של אינטל.
- **יצירת הקשרים בין טבלאות:** ארגון הנתונים בקשרים מבוססי עמודות מפתח בין טבלאות שונות כדי להבטיח זרימה אינטואיטיבית של מידע.
- **עיבוד נתונים:** בדיקת הנתונים, השלמת נתונים חסרים, ארגון באמצעות Unpivot, שילוב נתונים באמצעות Marge, הסרת כפילויות.

#### 3. פיתוח הדאשבורד וויזואליזציות [ראה נספח 3]

- **סוגי ויזואליזציות:** פיתוח גרפים אינטראקטיביים, טבלאות ומטריצות להצגת תחזיות ביקוש, יכולות אספקה ויכולות הייצור בהתאם למסמך הדרישות [ראה נספח 2].
- **עיצוב מקצועי:** הפיכת הדאשבורד לקריא ומבוסס על עיצוב ברור ומקצועי שמסייע להבין זוויות שונות של נתונים.
- **פילטרים וסינונים:** הוספת אפשרות סינון שיעזרו למשתמשים להתאים תצוגות ולהציג נתונים מזוויות שונות, כולל יכולות לבצע Drill-down לפרטים נוספים בתהליכים ספציפיים.

#### 4. בדיקה ואימות

- **בדיקת תקינות:** בדיקות על הדאשבורד, התוכן והאינטראקטיביות כדי להבטיח שהכל עובד לפי המטרות והתצוגה המיועדת.
- **משוב משתמשים:** קבלת תגובות מהמשתמשים הפוטנציאליים ומהנדסים כדי לזהות נקודות לשיפור והתאמה לצרכים הארגוניים.

#### 5. פרסום ושיתוף

- **פרסום הדאשבורד:** שיתוף עם משתמשים בהתאם להרשאות נדרשות.
- **הסבר והדרכה:** מתן הכשרה והדרכות למשתמשים על שימוש באינטראקטיביות ובאינטגרציה עם מודלים חיצוי.

#### 6. תחזוקה ועדכון (עתידיים)

- **רענון נתונים:** תכנון לרענון אוטומטי חודשי כדי לוודא שהדאשבורד מציג נתונים עדכניים ומדויקים.
- **שיפורים עתידיים:** התאמה ושיפור על בסיס משוב ממשתמשים תוך התייחסות להיבטים חדשים שעלו לאחר השקה ראשונית.

### 10.2. בעיה שנייה: חוסר דיוק בתחזית הביקוש. הפתרון: פיתוח אלגוריתם לחיזוי הביקוש

כיום אינטל חוזה את נתוני הביקוש באמצעות חישוב פשוט: כמות הביקושים לפי חוזים שנסגרו מול הלקוחות + חוזים שעוד לא נסגרו באחוז ביטחון של 90%. לאחר בניית הדאשבורד ויצירת גרף התפלגות נתוני הביקוש לכל טכנולוגיה לאורך השנים, ראינו שכל טכנולוגיה מתנהגת באופן שונה, ולכן ניתן לאפיין כל טכנולוגיה:

- טכנולוגיה 1: מחזוריות ותנודתיות, צמיחה והיחלשות.
- טכנולוגיה 2: צמיחה ורגישות.
- טכנולוגיה 3: טכנולוגיה חדשה וצומחת.

מכאן הגענו למסקנה שעבור כל טכנולוגיה נבחן מודל חיזוי שהכי מתאים לאיפיון שלה. המודל האופטימלי לכל טכנולוגיה יבחר לפי הביצועים ומדדי הערכה (R-Squared, MAPE, RMSE)

## 10.2.i. ניסויים לבחירת המודל האופטימלי:

➤ ניסוי ראשון - שימוש בספריית Lazy Predict :

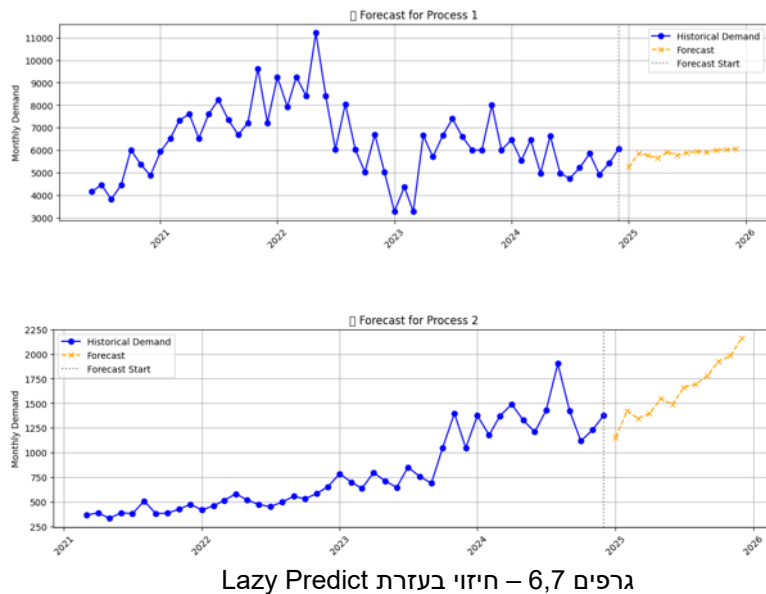
**מטרת הניסוי:** ספריית פייתון זו מאפשרת השוואה מהירה של ביצועי מודלים שונים ללמידת מכונה. היא מאמנת מספר מודלים באופן אוטומטי ומציגה תוצאות כגון דיוק וזמן ריצה, כדי לעזור לבחור את המודל האופטימלי בשלבי החקירה הראשוניים.

**התוצאה:** אלגוריתם Lazy Predict זיהה שלטכנולוגיה 1 המודל האופטימלי הוא Poisson Regressor עם RMSE של 408.72 , ולטכנולוגיה 2 המודל האופטימלי הוא ElasticNetCV עם RMSE של 190.8. עבור טכנולוגיה 3 התקבלו מדדי R-Squared שליליים, מכיוון שזו טכנולוגיה חדשה שאינה מכילה מספיק נתונים לחיזוי בעזרת אלגוריתם Lazy Predict.

➤ ניסוי שני - ביצוע רגרסורים באופן ידני:

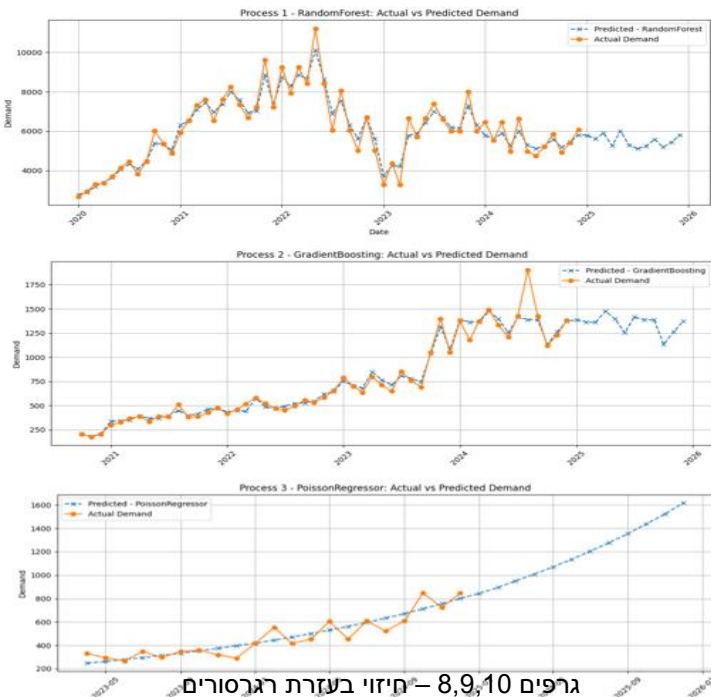
**מטרה:** בעוד ש-Lazy Predict הוא כלי שימושי לניתוח מהיר וראשוני של מגוון מודלים, ביצוע הרגרסורים בצורה ידנית מאפשרת התאמה אישית ובקרה עמוקה יותר, כגון: התאמת Train-Test hyperparameter .

**תוצאה:** לפי ניסוי זה המודל האופטימלי לטכנולוגיה 1 הוא Random Forest עם RMSE של 1246.7 (פחות טוב מהניסוי הקודם), המודל האופטימלי עבור טכנולוגיה 2 הוא Gradient Boosting עם RMSE של 171.17 (שיפור מהניסוי הקודם), והמודל האופטימלי לטכנולוגיה 3 הוא Poisson Regressor עם RMSE של 67.93.



	Process	Model	Experiment	R-Squared	RMSE	Time Taken (s)
0	Process 1	PoissonRegressor	Lazy Predict	0.60	408.72	0.19
1	Process 2	ElasticNetCV	Lazy Predict	0.03	190.81	0.25



טבלה 2- תוצאות ניסוי 1



	Process	Model	Experiment	R-Squared	RMSE	Time Taken (s)
2	Process 1	RandomForest	Regressors	0.26	1246.76	0.58
3	Process 2	GradientBoosting	Regressors	0.87	171.17	0.12
4	Process 3	PoissonRegressor	Regressors	0.79	67.93	0.06

טבלה 3 - תוצאות ניסוי 2

## ➤ ניסוי שלישי - שימוש במודל Prophet :



גרפים 11,12 – חיזוי בעזרת Prophet

Process	Model	Experiment	R-Squared	Adjusted R-Squared	RMSE	Time Taken (s)
6 Process 1	Prophet	Prophit	0.06	0.04	1708.69	0.39
7 Process 2	Prophet	Prophit	0.85	0.85	160.44	0.34

**מטרה:** מודל סטטיסטי שמבצע חיזוי של סדרות זמן על ידי שילוב מספר רכיבים: מגמות בסיס, עונתיות והשפעת חגים ואירועים. הספרייה מספקת יכולת להתמודד עם נתונים חסרים ואי-סדירות בהיסטוריה הדאטה.

**תוצאה:** מודל זה מתאים לטכנולוגיות בעלות מחזוריות ברורה, כמו טכנולוגיה 2 שהציג RMSE של 160.44. מודל זה לא מתאים לטכנולוגיות צומחות כמו טכנולוגיה 1 שהציג RMSE לא הציג ביצועים מספיק טובים (1708.7) וטכנולוגיה 3 שמכיוון שהיא טכנולוגיה חדשה היא לא מכילה מספיק נתונים על מנת להשתמש במודל זה.

טבלה 4 – תוצאות ניסוי 3

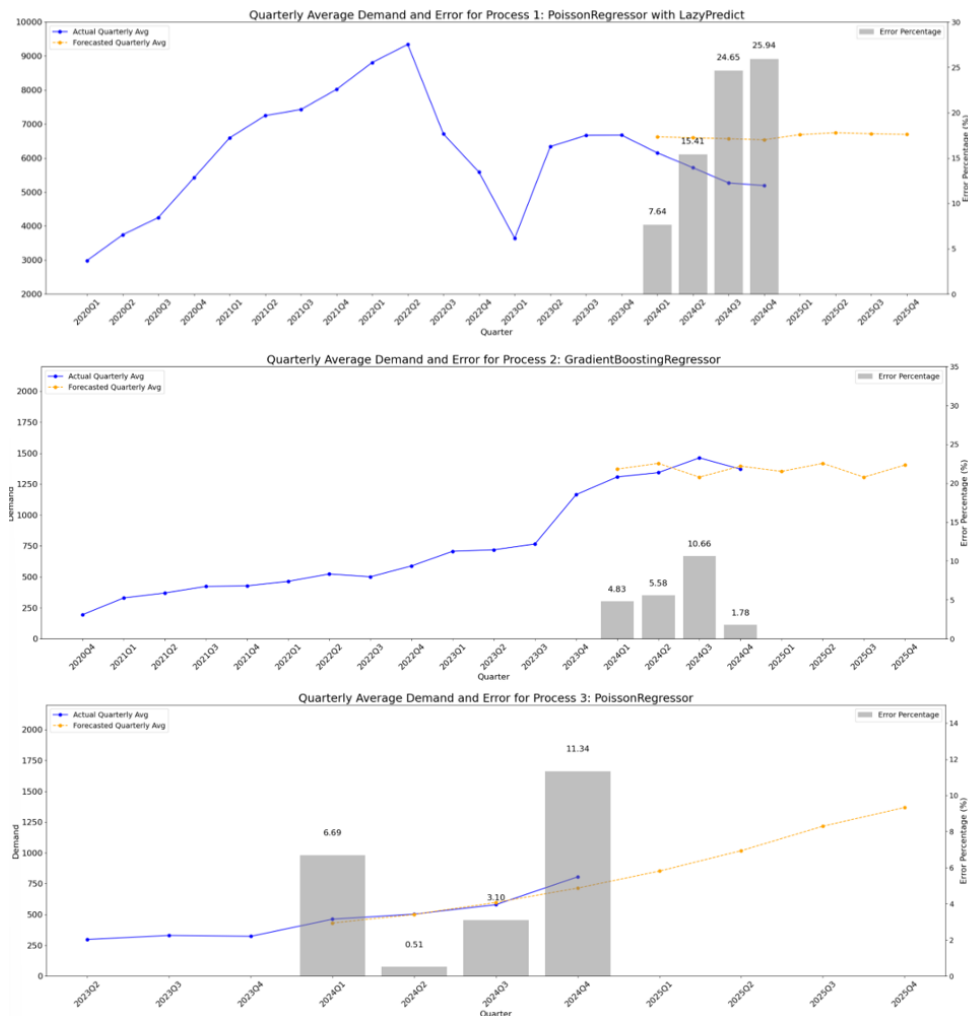
## 10.2.ii. הפתרון הנבחר

לאחר שלושת הניסויים בחרנו עבור כל טכנולוגיה את המודל האופטימלי לפי מדדי RMSE, ו-R-Squared:

- **טכנולוגיה 1:** מודל Poisson regressor לפי אלגוריתם Lazy Predict, הציג את ביצועי RMSE הטובים ביותר של 408.72, R-Squared של 0.6, ו-MAPE של 18.4.
- **טכנולוגיה 2:** מודל Gradient Boosting לפי אלגוריתם רגרסור ידני הציג RMSE של 171.17, R-Squared של 0.87, ו-MAPE של 5.7.
- **טכנולוגיה 3:** מודל Poisson regressor לפי אלגוריתם רגרסור ידני הציג RMSE של 67.93, R-Squared של 0.79, ו-MAPE של 5.41.

Process	Model	Experiment	R-Squared	RMSE	Time Taken (s)
0 Process 1	PoissonRegressor	Lazy Predict	0.60	408.72	0.04
1 Process 2	GradientBoosting	Regressors	0.87	171.17	0.12
2 Process 3	PoissonRegressor	Regressors	0.79	67.93	0.06

טבלה 5 – התוצאות האופטימליות מכל הניסויים



גרפים 13,14,15 – החיזוי האופטימלי לכל טכנולוגיה

### 10.3. משוב מהמשתמשים

לאחר בניית הדאשבורד ובניית המודלים הצגנו למהנדסים את התוצאות שהתקבלו, וביצענו שאלון קצר עם המנחה התעשייתי על מנת לבדוק כיווני שיפור:

? **אוטומציה וקיצור זמני עבודה:** מהי התרשמותך מהאוטומציה שהצגנו? האם היא תפחית את העומס ותפנה מהנדסים למשימות בעלות ערך גבוה יותר?

➤ פוטנציאל אדיר! זה משחרר שעות עבודה קריטיות של מהנדסים מפעולות סזיפיות. הם יוכלו להתמקד בניתוח עמוק, שיפור תהליכים ואופטימיזציה של שרשרת האספקה.

? **ויזואליזציה:** מה דעתכם על האופן שבו המערכת מציגה נתונים? האם הוויזואליזציות בהירות ומובנות?

➤ הוויזואליזציות נראות ברורות ואינטואיטיביות, ויש יתרונות ברורים ביכולת לראות את הנתונים בצורה גרפית.

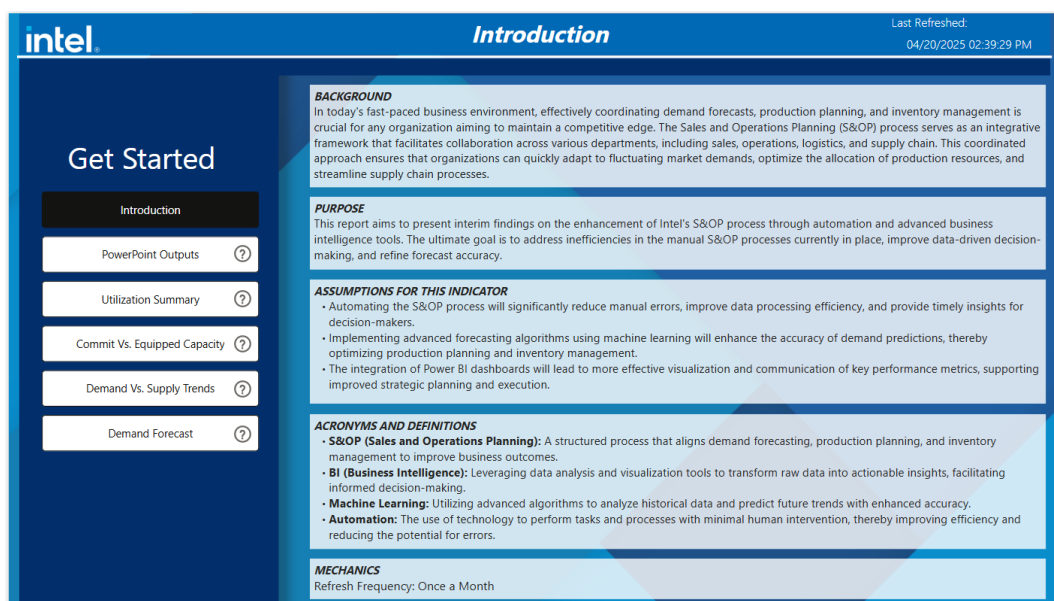
- נקודות לשיפור:** כדאי להוסיף טאב הקדמה שמסביר על מטרת הדאשבורד, רקע לתהליך, הנחות שהונחו, תדירות רענון הדוח, מושגים והסברים.
- ? **קלות השימוש:** איך אתם מעריכים את קלות השימוש במערכת המוגדרת? האם יש חלקים שנראים מורכבים יותר לשימוש?
- באופן כללי, המערכת ברורה מאד ונוחה לשימוש.
- ? **הפחתת טעויות אנוש:** איך המערכת החדשה תתרום להפחתת טעויות אנוש?
- המערכת מבטלת לגמרי נקודות כשל אנושיות בהזנות וחישובים ידניים. זה מבטיח אמינות נתונים גבוהה יותר, ומוביל לשקט נפשי למנהלים ומהנדסים, ולקבלת החלטות בטוחה יותר.
- ? **מודל החיזוי:** האם אחוז הדיוק של המודל מספק, ואיך המודל לחיזוי הביקושים ישפיע על תכנון ייצור וקבלת החלטות יומיומית?
- מודל אמין יאפשר תכנון ייצור אופטימלי (ניצול משאבים טוב יותר, הפחתת שינויים), וקבלת החלטות מהירה ובטוחה יותר על בסיס נתונים.
- נקודות לשיפור:** כדאי אולי לנסות ולשפר את אחוז הדיוק עבור Process 1.

## 10.4. כיוולים שינויים ושיפורים

לאחר קבלת המשוב, ביצענו כיוולים ושיפורים הן לדאשבורד והן לביצועי מודל החיזוי:

### 1. Power BI:

הוספנו עמוד הסבר והכוונה שכוללים את מטרות הדו"ח, הנחות, מושגים, והגדרות. בנוסף, נוצר תפריט ניווט בין העמודים כדי לשפר את חוויית המשתמש והפשטות בניהול המידע.




איור 5- תצלום מסך מהדאשבורד




## 2. שיפור מודל חיזוי:

לפי הניסויים שביצענו, המודל האופטימלי לטכנולוגיה 1 לפי מדדי הערכה RMSE ו-R-squared הוא Poisson regressor לפי אלגוריתם Lazy Predict. אחוז השגיאה שהתקבל (MAPE) הוא 18.4%. אחוז שגיאה זה גבוהה יותר מהמצב התחלתי ללא מודל שהיה 11.25%. לכן, על מנת להתחשב בכל מדדי ההערכה, בחרנו את המודל האופטימלי הבא בתור מבחינת מדדי RMSE ו-Squared-R שהוא Random Forest לפי אלגוריתם של גרסור ידני. אומנם ה-RMSE גבוהה יותר (1228.11 לעומת 408.72 וה-R-Squared נמוך יותר (0.28 לעומת 0.6) אך אחוז השגיאה (MAPE) השתפר מ-18.4% ל-6.5%.



גרף 16- החיזוי לפני שיפור המודל



גרף 17- החיזוי אחרי שיפור המודל

## 11. הערכת הפתרון

### זמן עיבוד נתונים

**מצב קודם:** תהליך איסוף, ניקוי וניתוח הנתונים בוצע כולו באופן ידני בקבצי אקסל. מרגע שהמידע היה מתקבל, נדרשו בממוצע כ-6.3 ימי עבודה מלאים בכל חודש עד שהדוחות היו מוכנים להצגה להנהלה. מדובר, בתהליך רצוף פעולות חזרתיות – חיבור קבצים, בדיקות עקביות, חישובים ידניים, ויצירת גרפים – שכל שלב בו היה תלוי בביצוע אנושי.


**לאחר הטמעה:** המערכת החדשה מבצעת את כל תהליך האיסוף, החישוב והוויזואליזציה באופן אוטומטי לחלוטין. כל מה שנדרש מהמשתמש הוא לחיצה אחת על כפתור, שלאחריה מתקבלים הדוחות המעודכנים בתוך שניות ספורות. השינוי הזה לא רק ביטל לחלוטין את הצורך בימי העבודה הארוכים, אלא גם הפך את הגישה למידע למיידית – בכל רגע, מכל מקום – מה שמאפשר קבלת החלטות עסקיות קריטיות בזמן אמת, ללא המתנה.

### דיוק תחזיות (MAPE)

**מצב קודם:** אחוזי השגיאה בתחזיות הביקוש היו גבוהים: טכנולוגיה 1 - 11.25%, טכנולוגיה 2 - 38.25%, טכנולוגיה 3 - 28.5%.

**לאחר הטמעה:** שיפור ניכר נרשם באחוזי דיוק תחזיות הביקוש (MAPE) בכל טכנולוגיה:

- ✓ בטכנולוגיה 1 קיים שיפור של כמעט 5%, מ- 11.25% ל- 6.56%.
- ✓ בטכנולוגיה 2 קיים שיפור ניכר של מעל 30%, מ- 38.25% ל- 5.72%.
- ✓ בטכנולוגיה 3 קיים שיפור ניכר של מעל 20%, מ- 28.5% ל- 5.41%.



גרף 18- השוואת אחוז השגיאה (MAPE) בכל אחד משלבי הפרויקט

## **יעילות עבודה - צמצום כוח האדם:**

**מצב קודם:** ארבעה מהנדסים היו מעורבים ישירות בניתוח הנתונים ובהכנת המצגת.

**לאחר הטמעה:** בזכות האוטומציה, נדרשת כעת מעורבות של מהנדס אחד בלבד לניהול וניטור התהליך, מה שמפנה את יתר כוח האדם למשימות אסטרטגיות נוספות. התפנה זמן המביא לשיפור במחלקות אחרות ולמימוש יוזמות טכנולוגיות נוספות, שנדרשות כדי לעמוד בקצב השוק.

## **הפחתת טעויות אנוש**

**מצב קודם:** בתהליך הידני התגלו בממוצע 3 טעויות בחודש עקב הזנות ידניות ושימוש לא נכון בנוסחאות, מה שהוביל לעיתים להצגת נתונים לא מדויקים והאט את תהליך קבלת ההחלטות.

**לאחר הטמעה:** ההסתמכות על מערכת אוטומטית לביצוע ניתוחים וחישובים הפחיתה לחלוטין את הופעתן של טעויות אנושיות, ובכך שיפרה את אמינות התוצאות. הנתונים המדויקים והמהימנים מאפשרים לקבל החלטות בהתבסס על מידע נכון, מה שתורם לריכוז מאמצים בהיבטי אנליזה והבנת נתונים.

## **קבלת החלטות:**

**מצב קודם:** התהליך לקבלת החלטות ארגוניות היה מוטרד מהזמן שלקח לייצר את התובנות הנדרשות ולעתים עבר חודש לפני ששרשרת המנהלים יכלה להתחיל בתכנון פעולה.

**לאחר הטמעה:** המערכת האוטומטית הקטינה את זמן הכנת הנתונים למספר ימים בלבד, מה שאיפשר להציג את המצגת תוך כ-3 שבועות לכלל המנהלים. ההאצה המהותית בתהליך משליכה על יכולת הארגון להגיב לשינויים בשוק במהירות ובגמישות, וכך להוביל למהלכים עסקיים קודמים ומניעת הפסדים פוטנציאליים. יתרה מכך, פעולה זריזה זו מניבה יתרון תחרותי על פני מתחרים המסתמכים על תהליכים איטיים יותר.

## 12. דיון מסקנות והמלצות

בתחילת הפרויקט התברר כי תהליך ה-S&OP-באינטל התנהל באופן ידני בעזרת קבצי אקסל, מהלך שדרש בממוצע 6.3 ימי עבודה בכל חודש. התהליך כלל שלבים חזרתיים ומונטוניים, היה רגיש לטעויות אנוש וגרר עיכובים משמעותיים בקבלת החלטות – לעיתים אף חודש שלם לאחר תחילת התהליך. המידע הוצג בקבצים סטטיים, דבר שהקשה על זיהוי מגמות והבנת תמונת המצב המלאה. בנוסף, תחזיות הביקוש התבססו על חישובים פשוטים ללא כלים אנליטיים מתקדמים, מה שהוביל לסטיות משמעותיות, בעיקר בטווח הארוך, לעיתים תוך יצירת עודפי מלאי או מחסור במוצרים קריטיים.

בעקבות הפרויקט, אוטומציה של התהליך ופיתוח אלגוריתמים לחיזוי הביקושים, קרה שיפור בכל המדדים שנבדקו: קיצור זמני העבודה, שיפור דיוק החיזוי, צמצום כוח אדם, הפחתת טעויות אנוש וייעול תהליך קבלת ההחלטות.

הדאשבורד שפותח כולל ויזואליזציות אינטראקטיביות המציגות בזמן אמת את כלל הנתונים הדרושים בצורה ברורה ומובנת לשרשרת המנהלים, ומאפשרות קבלת החלטות חכמות מבוססות נתונים. בנוסף, הוא משלב מודלים מבוססי למידת מכונה המותאמים לכל טכנולוגיה, תוך שימוש בנתוני עבר לחיזוי ביקושים לשנתיים הקרובות. מודלים אלו משפרים את תוצאות חיזוי הביקושים ומוסיפים רובד מתקדם המסתמך על למידת מכונה בנוסף לחיזויים הפשוטים שהיו נהוגים בעבר.

השינויים שנעשו במסגרת הפרויקט הדגישו את הפוטנציאל הטמון בטכנולוגיה לשיפור תהליכים ארגוניים והשגת יעילות גבוהה יותר. האוטומציה והמודלים החדשניים מוכיחים את עצמם ככלים שיכולים לסייע לאינטל להבין את השוק בצורה טובה יותר, לתכנן בצורה מדויקת ולקבל החלטות מושכלות ומהירות יותר. באמצעות שדרוגים אלו, אינטל יכולה כעת להיערך לשינויים עתידיים ולאמץ תהליכי עבודה מתקדמים שיעזרו לה לשמור על יתרונה התחרותי. הפרויקט שימש לא רק כפתרון קצר-טווח אלא גם כאבן דרך להתפתחות ולהתקדמות ארגונית כוללת.

### 12.1. תובנות מרכזיות

#### א. ניצול טכנולוגיה להובלת שינוי ארגוני וייעול תהליכים:

השימוש בכלי אוטומציה כמו Power BI ואלגוריתמי למידת מכונה הדגיש את הפוטנציאל לשנות תהליכים ארגוניים מסורתיים ולייעל את הפעילות העסקית. המערכת האוטומטית לא רק חסכה זמן משמעותי, אלא גם שיפרה את דיוק התחזיות והפחיתה טעויות אנוש. ביטול התלות בתהליכים ידניים האיץ את יעילות עבודת המהנדסים, פינה זמן קריטי לטובת משימות אסטרטגיות בעלות ערך גבוה יותר, וכמובן מאפשר קבלת החלטות מושכלות ומהירות יותר.

## ב. חשיבות השימוש במודלים של למידת מכונה:

ההשוואה בין מודלים שונים הדגישה את ההבדלים בצורות ניבוי שונות עבור כל טכנולוגיה. השימוש במדד הערכה מתאים, כגון MAPE, RMSE ו-R-Squared, איפשר לבחור את מודל החיזוי האופטימלי. מדדי הערכה אלה סייעו לאתר את המודלים המציעים תחזיות מדויקות ומקטינים את הסטיות, מה שאיפשר לאינטל לתכנן ייצור ומלאי בצורה מיטבית. הבחירה במדד הערכה המתאים קריטית להבטחת דיוק התחזיות, שכן כל מדד מספק מבט אחר על ביצועי המודל, ויכול להשפיע באופן משמעותי על הצלחת התכנון.

## ג. שיפור קבלת החלטות עסקיות:

החזות המיידית והגישה האינטראקטיבית לנתונים באמצעות דאשבורד Power BI מוביל לשיפור משמעותי בתהליך קבלת החלטות. מנהלים יכולים לקבל החלטות מושכלות ומהירות יותר על בסיס נתונים עדכניים ואמינים.

## 12.2. מסקנות והמלצות

### 1. שיפור מתמשך וחקירת כלים אנליטיים נוספים:

יש צורך להמשיך ולשפר את מודלי החיזוי במיוחד עבור טכנולוגיות עם אחוזי שגיאה גבוהים יותר. ניתן לחקור ולהטמיע כלים נוספים לניתוח תרחישים ואופטימיזציה, כגון ניתוח רגישות ו-What-if Analysis, על מנת לשפר את תהליך ה-S&OP ולהתאים בצורה מיטבית לדרישות המשתנות של השוק.

### 2. הגדלת האינטגרציה עם מערכות קיימות:

מומלץ לחבר את הדאשבורד למערכות מידע ארגוניות בזמן אמת. פעולה זו תשפר את דיוק החיזוי והבקרה, ותייצר סנרגיה בין המערכות השונות בארגון, וכתוצאה מכך תוביל לשיפור במימוש מטרות עסקיות וארגוניות.

### 3. הפעלת המידע והנסיון לשיפור תהליכים נוספים:

ניתן להשתמש בפתרונות שפותחו בפרויקט זה כמודל לשיפור תהליכים נוספים בארגון, הן במחלקות השונות והן בפרויקטים חדשים.

## 12.3. תרומת חברי הצוות להצלחת הפרויקט

- **מרינה נז'לסקי** – ידע עיסקי מתוך אינטל, הובלת פיתוח הדאשבורד ב-Power BI, עיצוב ויזואליזציות, איסוף ועיבוד הנתונים, והקמת תשתית הנתונים.
- **עדן כהן** – פיתוח מודלי החיזוי, ביצוע ניסויים ואופטימיזציות במודלים שונים.
- **איל קדוש** – ניתוח המצב הקיים, תיאום עם המהנדסים והכנת חומרי ההדרכה למערכת.

- [1] Kalluri, K. (2023). Assessing the impact of Pega's robotic process automation on supply chain management efficiency. *International Journal of Scientific Research in Engineering and Management (IJSREM)*, 7(6), 1-6. <https://doi.org/10.55041/IJSREM22935>
- [2] Yeoh, W., & Koronios, A. (2015). Critical Success Factors for Business Intelligence Systems. *Journal of Computer Information Systems*. ISSN: 0887-4417
- [3] Kim & Sehoon (2023), Innovating knowledge and information for a firm level automobile demand forecast system: A machine learning perspective, *Journal of Innovation & Knowledge*, ISSN: 100355
- [4] Islam, R. (2013). Improving productivity and profitability of a bioanalytical business through sales and operation planning. Taylor & Francis Ltd, 2-4 Park Square, Milton Park, Abingdon OR14 4RN, Oxon, England. ISSN: 1757-6180
- [5] Nafis, A., Ibrahim, M. A. A., Syed, S. R. M., Shah, S. S. A., Tahir, M. H., & Zou, Y. (2025). Data mining and machine learning-based search for optimal materials for perovskite and organic solar cells. *Solar Energy*. Elsevier, Radarweg 29, 1043 NX Amsterdam, Netherlands. ISSN: 0038-092X.
- [6] Brandon, W. (2023). Regression model evaluation metrics: R-squared, adjusted R-squared, MSE, RMSE, and MAE. Medium. A Medium Corporation, 760 Market Street, 5th Floor, San Francisco, CA 94102, USA.

**[1] סקר ניתוח תהליך למצב הנוכחי**

1. האם אתה חושב שיש מקום לשיפור וייעול התהליך הנוכחי?



2. במהלך סייקל, כמה שעות יומיות בממוצע את מקדיש לתהליך ניתוח נתונים ולכניית המצגת?



3. (לדעתך, מהו אחוז הזמן שמוקדש לתהליכים שחוזרים על עצמם? (כהגדרתם כשימויות שחוזרות על עצמן באותה צורה בדיוק, מתוך סך כל הזמן הנדרש לניתוח נתונים בכל חודש



4. כמה פעמים בחודש אתה נדרש לעדכן או לתקן נתונים בעקבות טעויות שהתגלו?



5. כמה אנשים נדרשים כדי לבצע את התהליך מתחילתו ועד סופו



6. האם אתה נתקל בתקלות בזמן התהליך-תגובות חריגות, נתונים חסרים וכו

(לעולם לא-1, כמעט לא-2, לפעמים-3, לרוב-4, כל הזמן-5)



7. באיזו תדירות אתה מאמין שמידע חשוב מתפספס או מתעכב עקב חוסר סנכרון בין מחלקת הייצור ומחלקת הביקוש?  
(לעולם לא-1, כמעט לא-2, לפעמים-3, לרוב-4, כל הזמן-5)



8. באיזו מידה אתה מסכים עם ההיגד: "אני חש שפרודוקטיביות העבודה שלי נפגעת בעקבות עבודה ידנית ואקסלים"?



9. האם לדעתך הטמעת מערכת אוטומציה תוכל לשפר תהליך זה?



10. כמה זמן לדעתך יידרש לך להסתגל לעבוד עם מערכת אוטומציה חדשה?



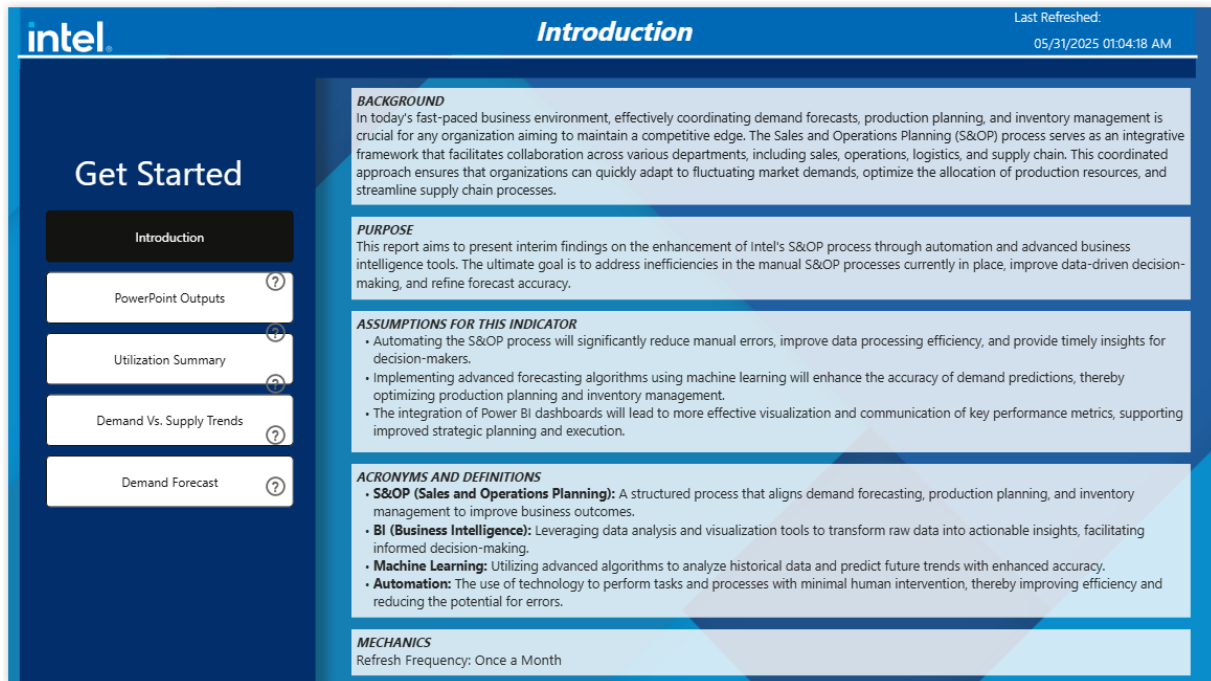


## [2] דוח דרישות

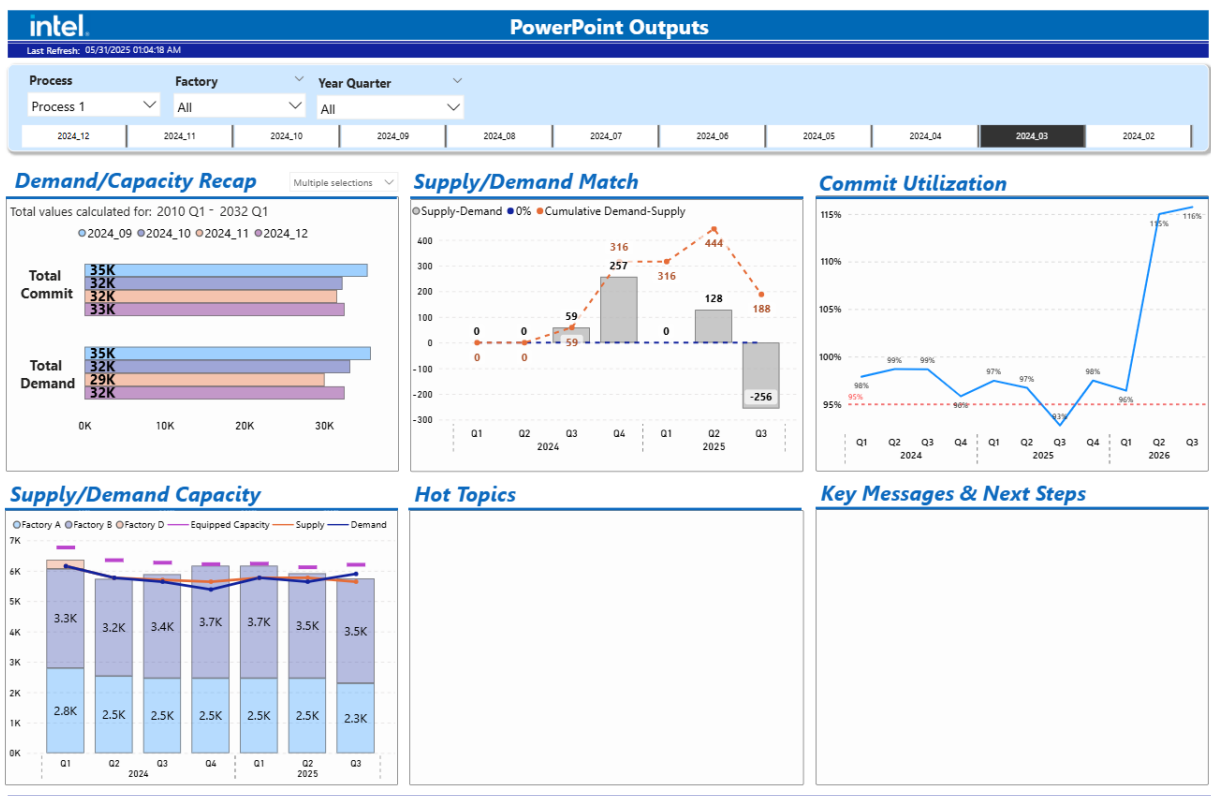
תיאור דרישה	סוג דרישה	תיעדוף (1- גבוה, 3-נמוך)	פירוט
איסוף נתונים אוטומטי	פונקציונלית	3	חיבור למסדי נתונים בזמן אמת, ללא צורך בתהליכים ידניים. תחילה הפרוייקט יוזן מקבצים סטטים, ובהמשך ההטמעה תתבצע על ידי חיבור למסדי הנתונים של אינטל.
ויזואליזציות אינטראקטיביות	פונקציונלית	1	<p><b>טאב מצגת:</b> לשונית זו תציג את עיקרי הניתוחים שיוצגו במצגת. הנראות צריכה להתאים למצגת פאוורפוינט.</p> <p><b>גרפים:</b></p> <ol style="list-style-type: none"> <li>1) ביקוש לעומת ייצור בכל חודש</li> <li>2) התאמת האספקה לביקוש, כולל ערכים מצטברים</li> <li>3) נצילות קיבולת הייצור</li> <li>4) אספקה וביקוש לעומת קיבולת הייצור</li> </ol> <p><b>טאב נצילות:</b> לשונית זו תציג את כל פילוחי הנצילות.</p> <p><b>גרפים:</b></p> <ol style="list-style-type: none"> <li>1) נצילות חודשית</li> <li>2) השוואת הנצילות חודש לחודש</li> <li>3) טבלת השוואה</li> </ol> <p><b>טאב אספקה מול ביקוש:</b> השוואה בין יכולות האספקה והביקוש לכל טכנולוגיה.</p> <p><b>גרפים:</b></p> <ol style="list-style-type: none"> <li>1) גרף ביקוש כולל עם הפער לאספקה, כולל ערכים מצטברים</li> <li>2) גרף פער בין אספקה וביקוש</li> </ol> <p><b>טאב חיזוי הביקושים:</b> טאב שמכיל את מודל החיזוי.</p> <p><b>גרפים:</b></p> <ol style="list-style-type: none"> <li>1) גרף חיזוי לפי חישובי אינטל, כולל אחוז שגיאה</li> <li>2) גרף חיזוי לפי מודל למידת מכונה, כולל אחוז שגיאה</li> </ol>
יכולות סינון ופילטרים	פונקציונלית	2	אפשרות לסנן טכנולוגיות, מפעלים, חודשי תכנון. עם אפשרות ל Drill down לשנים ורבעונים.

פירוט	תיעדוף (1-3 גבוה, 3-נמוך)	סוג דרישה	תיאור דרישה
אינטגרציה עם מאגרי מידע לשמירת נתונים היסטוריים, אפשרות להשוואה בין חודשי תכנון שונים.	2	פונקציונלית	הצגת מידע היסטורי
שילוב אלגוריתמים של למידת מכונה וסקריפטים של Python לשיפור דיוק התחזיות	1	פונקציונלית	חיבור למודלי חיזוי
התאמה עם מערכות ERP ו-MRP, ו-Power BI	1	טכנית	אינטגרציה עם מערכות קיימות
עיבוד נתונים מהיר	1	טכנית	ביצועים גבוהים
שמירה על פרטיות נתונים ותמיכה בהסכמי סודיות	2	טכנית	אבטחת מידע
ממשק ידידותי, מתאים גם למשתמשים לא טכנולוגיים	2	לא פונקציונלית	קלות השימוש
הסברים על מטרות המערכת והנחות בכל המסכים	3	לא פונקציונלית	שקיפות נתונים
יכולת לעדכון והטמעת שדרוגים	2	טכנית	תחזוקה רציפה

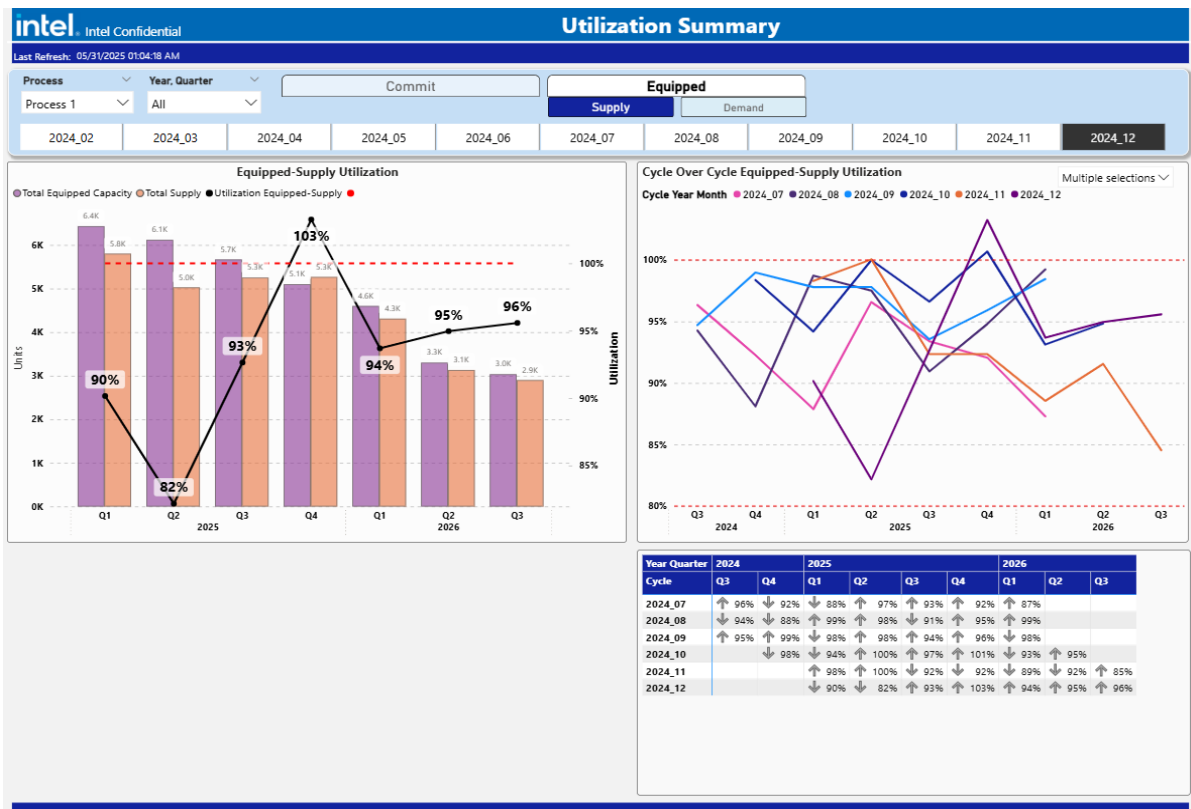
## טאב הקדמה



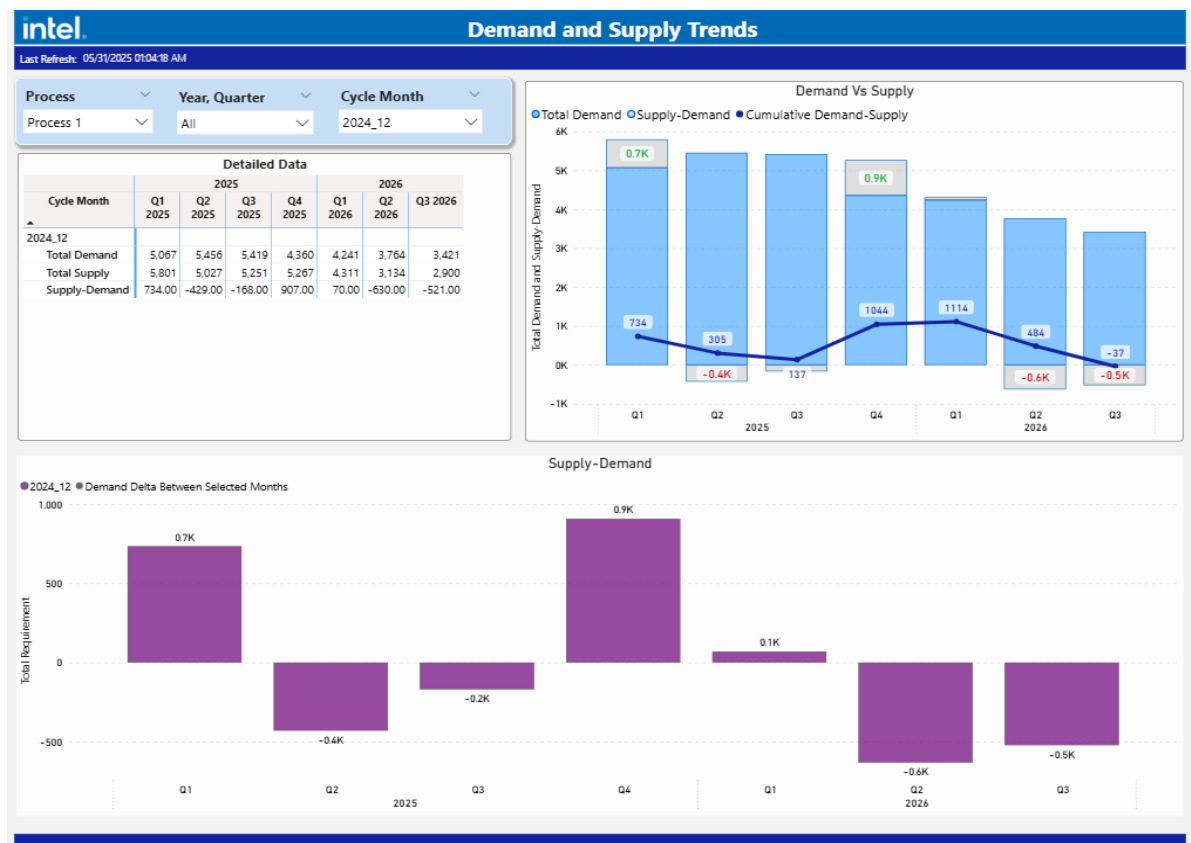
## טאב מצגת

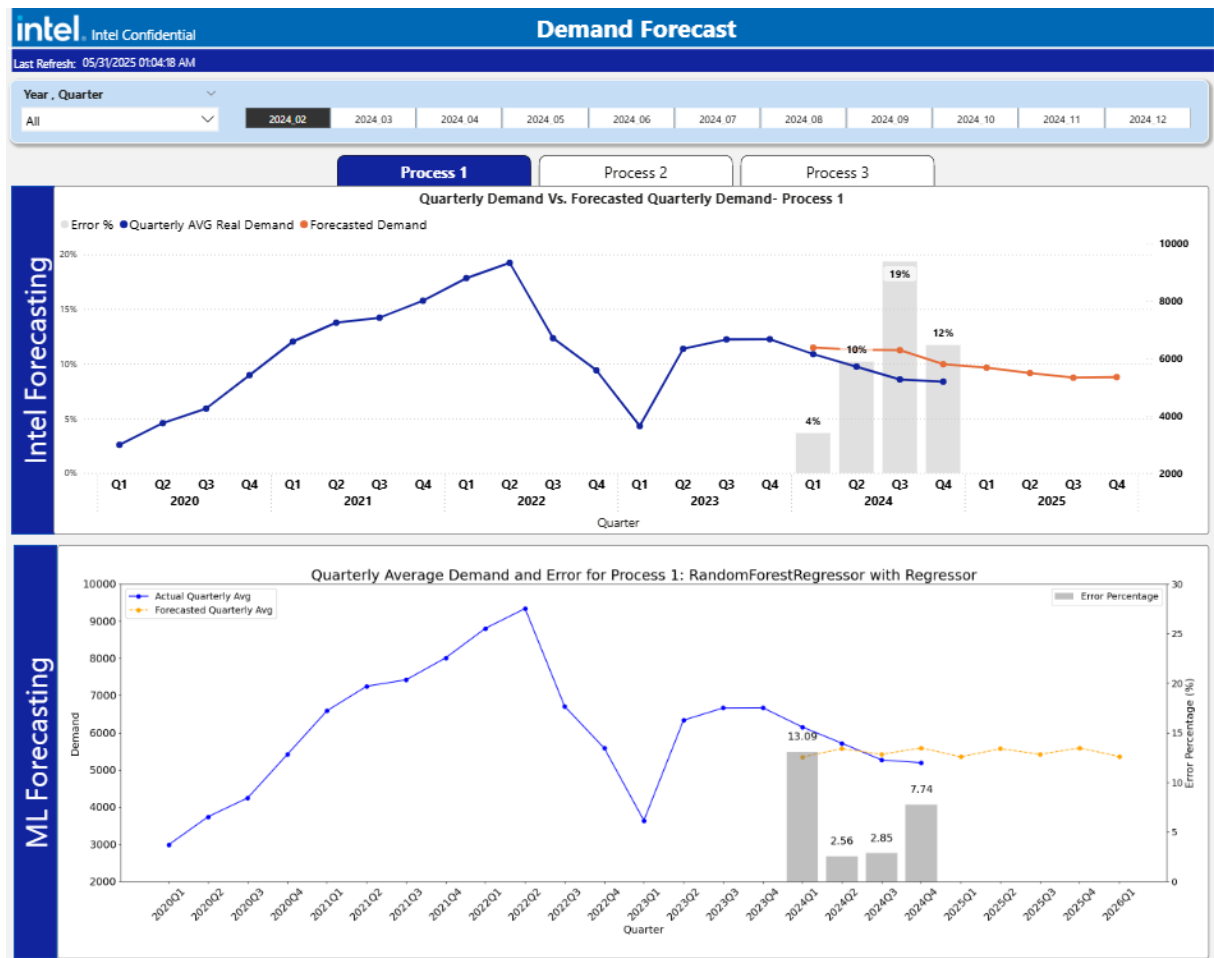


## טאב נצילות



## טאב אספקה לעומת ביקוש





להלן דוגמא לקוד עבור מודל החיזוי לטכנולוגיה 1 כפי שהוא מוטמא בויזואליזציות Python בדאשבורד. הנתונים והניסויים שנעשו על מגוון מודלים ושיטות מצורפים בכתובת: Github.

<https://github.com/MarinaNezhelsky/Industrial-Engineering-Final-Project/tree/main>

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
import numpy as np
import matplotlib.dates as mdates
from sklearn.ensemble import GradientBoostingRegressor

# dataset = pandas.DataFrame(Year, Quarter, Month, Process, Monthly_Demand)
# dataset = dataset.drop_duplicates()
# Function to convert month names to numeric values
def month_name_to_number(month_name):
    month_mapper = {
        "January": 1, "February": 2, "March": 3, "April": 4,
        "May": 5, "June": 6, "July": 7, "August": 8,
        "September": 9, "October": 10, "November": 11, "December": 12
    }
    return month_mapper[month_name]

# Convert month names to numeric
# Ensure the data is sorted by time
dataset.sort_values(by=['Year', 'Month'], inplace=True)

# Create Date for time series processing
dataset['Date'] = pd.to_datetime(dataset[['Year', 'Month']].assign(DAY=1))

# Assuming Demand_original_df is already defined and processed with
appropriate columns
process_name = "Process 1"
process_data = dataset[dataset['Process'] == process_name]

if len(process_data) >= 8:
    # Preparing the feature set
    X = process_data[['Year', 'Month']]
    y = process_data['Monthly_Demand']
    # Split the data into training and testing datasets
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
        random_state=42)

    # Scale features
```

```

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Train the RandomForest model
model = RandomForestRegressor(random_state=42)
model.fit(X_train_scaled, y_train)

# Prepare new data for the next 24 months forecasting
future_dates = pd.date_range(start=pd.to_datetime("2024-01-01"),
periods=24, freq='M')
future_X = pd.DataFrame({
    "Year": future_dates.year,
    "Month": future_dates.month
})
future_X_scaled = scaler.transform(future_X)

# Forecast future demand
forecast = model.predict(future_X_scaled)

# Convert future_dates to the first day of each month
future_dates_start = future_dates.normalize() + pd.offsets.MonthBegin(1)
process_data=process_data.dropna(subset=['Date'])

# Combine actual and forecasted data
process_data['Quarter'] = process_data['Date'].dt.to_period('Q')
future_dates_quarter = future_dates_start.to_series().dt.to_period('Q')
forecast_df = pd.DataFrame({'Date': future_dates_start,
'Forecasted_Demand': forecast, 'Quarter': future_dates_quarter})

# Combine actual data with forecast for complete horizon
combined_actual_forecast = pd.concat([
    process_data[['Date', 'Monthly_Demand', 'Quarter']],
    forecast_df[['Date', 'Forecasted_Demand', 'Quarter']]
], ignore_index=True)

# Calculate quarterly averages for actual data and forecast
quarterly_actual_avg =
combined_actual_forecast.groupby('Quarter')['Monthly_Demand'].mean().reset_ind
ex()
quarterly_forecast_avg =
combined_actual_forecast.groupby('Quarter')['Forecasted_Demand'].mean().reset_
index()

# Merge the quarterly actual and forecast averages
quarterly_merged_avg = pd.merge(quarterly_actual_avg,
quarterly_forecast_avg, on='Quarter', how='inner')

# Calculate quarterly error percentages based on averages
quarterly_merged_avg['Error_Percentage'] =
np.abs((quarterly_merged_avg['Monthly_Demand'] -

```

```

quarterly_merged_avg['Forecasted_Demand']) /
quarterly_merged_avg['Monthly_Demand']) * 100

# Plot quarterly averages
fig, ax1 = plt.subplots(figsize=(24, 8))

# Plot actual quarterly averages
ax1.plot(quarterly_merged_avg['Quarter'].astype(str),
quarterly_merged_avg['Monthly_Demand'], label='Actual Quarterly Avg',
marker='o', color='blue')

# Plot forecasted quarterly averages
ax1.plot(quarterly_merged_avg['Quarter'].astype(str),
quarterly_merged_avg['Forecasted_Demand'], label='Forecasted Quarterly Avg',
marker='o', linestyle='--', color='orange')

ax1.set_xlabel('Quarter', fontsize=16)
ax1.set_ylabel('Demand', fontsize=16)
ax1.set_title(f'Quarterly Average Demand and Error for {process_name}:
RandomForestRegressor with Regressor', fontsize=22)
ax1.tick_params(axis='x', rotation=45, labels=16)
ax1.tick_params(axis='y', labels=16)
ax1.set_ylim(2000, 10000)

# Create a secondary y-axis for the error bars
ax2 = ax1.twinx()
ax2.bar(quarterly_merged_avg['Quarter'].astype(str),
quarterly_merged_avg['Error_Percentage'], color='gray', alpha=0.5,
label='Error Percentage')
ax2.set_ylabel('Error Percentage (%)', fontsize=16)
ax2.tick_params(axis='y', labels=14)
ax2.set_ylim(0, 30)

# Add data labels to the bar plot
for i, row in quarterly_merged_avg.iterrows():
    error_percentage = row['Error_Percentage']
    if isinstance(error_percentage, (int, float)) and not
np.isnan(error_percentage):
        ax2.text(str(row['Quarter']), error_percentage + 1,
f"{error_percentage:.2f}", ha='center', va='bottom', fontsize=16)

fig.tight_layout()
ax1.legend(loc='upper left', fontsize=14)
ax2.legend(loc='upper right', fontsize=14)

plt.show()
else:
    print(f"Not enough data to perform RandomForest forecasting for
{process_name}.")

```